Universitat de Girona
Escola Politècnica Superior

Treball Final de Màster

Estudi: Màster en Ciència de Dades

Títol: Anàlisi de la codificació del gènere en representacions intermitges d'una Xarxa Neuronal Convolucional per estudi d'equitat en predicció de Pneumònia

Document: Memòria

Alumne: Joan Massallé Richart

Tutor: Jerónimo Hernández González
Departament: Informàtica, Matemàtica aplicada i Estadística
Àrea: Llenguatges i Sistemes Informàtics

Convocatòria: Juny 2026

Universitat de Girona
Escola Politècnica Superior

TREBALL FINAL DE MÀSTER

Anàlisi de la codificació del gènere en representacions intermitges d'una Xarxa Neuronal Convolucional per estudi d'equitat en predicció de Pneumònia

Autor:
Joan Massallé Richart

Juny 2026

Màster en Ciència de Dades

Tutors:
Jerónimo Hernández González

Resum

Malgrat el seu ús creixent en imatge mèdica, els models d'aprenentatge profund poden reproduir biaixos relacionats amb atributs com el gènere o l'ètnia, cosa que pot portar a resultats diagnòstics desiguals. Aquest treball examina com la informació sensible de gènere queda codificada en xarxes neuronals convolucionals (CNN) entrenades per detectar pneumònia en radiografies de tòrax, i si l'aplicació explícita d'una restricció de *fairness* té un impacte en aquesta codificació.

L'estudi empra principalment el dataset NIH ChestX-ray per a la predicció de pneumònia, i posteriorment s'ha estès l'anàlisi al dataset CheXpert. La pipeline implementada és genèrica i suporta qualsevol dataset de radiografies amb el format adequat. Després d'un preprocessament estàndard (filtrat, redimensionat, normalització i divisió train-test), les imatges s'utilitzen per entrenar un model. L'entrenament utilitza una funció de pèrdua que combina l'entropia creuada estàndard per a la tasca de classificació, amb un terme de regularització de *fairness*, que penalitza el biaix mesurat en aquest projecte com la diferència en les taxes de vertaders positius (TPR) entre gèneres. Les representacions intermèdies de sis capes s'extreuen per analitzar com la informació de gènere queda codificada al llarg de la xarxa.

La hipòtesi central del treball és que, a l'hora de forçar el model a ser just, aquest necessita codificar activament el gènere del pacient en les seves representacions internes per tal d'igualar el seu comportament entre grups. És a dir, paradoxalment, l'aplicació de la restricció de *fairness* pot incrementar la presència d'informació de gènere a les capes de la xarxa, en lloc d'eliminar-la. Aquest treball té com a objectiu entendre i quantificar aquest fenomen, i analitzar com varia en funció de la capacitat del model i del pes de la penalització per biaix. El propòsit és millorar la comprensió del biaix en models neuronals per promoure sistemes de diagnosi més equitatius.

Els experiments revelen que, en el rang de valors baixos d'α (el pes de la penalització de *fairness*), la penalització de *fairness* és pràcticament inerta: el biaix de gènere i la codificació del gènere a les representacions intermèdies no es veuen afectats de manera significativa. En augmentar α fins a rangs molt més elevats, apareix un *fairness-accuracy trade-off* clar: a partir d'un llindar crític ($\alpha \approx 25$–50 per al NIH ChestX-ray), la penalització produeix una reducció substancial del biaix però a cost d'una degradació severa de la qualitat diagnòstica, fins a nivells propers al classificador aleatori en els extrems. La mida de la capa intermèdia és el principal determinant de la decodificabilitat del gènere, per sobre del pes de la penalització. Contràriament a la hipòtesi de partida,

augmentar α no incrementa la codificació del gènere a les representacions intermèdies de manera rellevant. La comparació entre NIH ChestX-ray i CheXpert mostra que el biaix inherent al CheXpert és considerablement inferior, si bé els patrons qualitatius es reprodueixen en ambdós conjunts de dades.

Agraïments

Vull expressar el meu agraïment al meu tutor, el Dr. Jerónimo Hernández González, per la seva guia constant al llarg de tot el projecte, les discussions periòdiques sobre els resultats i la seva predisposició permanent a resoldre dubtes i orientar les decisions experimentals.

Vull agrair també a la Vien Ngoc Dang la seva disponibilitat per compartir coneixements i experiències derivades de la seva recerca en l'àmbit del biaix en models d'imatge mèdica, que han contribuït a enriquir la perspectiva d'aquest treball.

Finalment, vull donar les gràcies al grup de recerca GILAB de la Universitat de Girona per facilitar l'accés als recursos computacionals (GPU) que han fet possible l'execució dels experiments d'aquest treball.

Índex

1 Introducció **1**
- 1.1 Context i motivació . . . 1
- 1.2 Problema i qüestions de recerca . . . 2
- 1.3 Treballs relacionats i posicionament . . . 2
- 1.4 Contribucions . . . 3
- 1.5 Estructura del document . . . 4

2 Estat de l'art **5**
- 2.1 *Fairness* (justícia) en aprenentatge automàtic . . . 5
- 2.2 Biaix en models de diagnosi mèdica . . . 5
- 2.3 Anàlisi de representacions internes . . . 6
- 2.4 Mètodes de regularització per a *fairness* . . . 7

3 Preliminars **9**
- 3.1 Domini: pneumònia i radiografia de tòrax . . . 9
- 3.2 Datasets emprats . . . 9
  - 3.2.1 NIH ChestX-ray . . . 9
  - 3.2.2 CheXpert . . . 10
  - 3.2.3 Altres datasets considerats . . . 10
- 3.3 Model: ResNet18 . . . 10
- 3.4 Nocions de *fairness* emprades . . . 11
  - 3.4.1 Taxa de vertaders positius (TPR) . . . 11
  - 3.4.2 Penalització de *fairness* basada en TPR . . . 11

4 Planificació i Metodologia **13**
- 4.1 Metodologia general . . . 13
- 4.2 Planificació temporal . . . 14
- 4.3 Costos de realització . . . 14
- 4.4 Pipeline d'entrenament . . . 14
- 4.5 Disseny del sweep experimental . . . 15

5 Contribució Metodològica **17**
- 5.1 Regularització de *fairness* basada en diferència de TPR . . . 17

6 Resultats **19**
- 6.1 Rendiment diagnòstic i biaix de gènere . . . 19
  - 6.1.1 Rang baix d'α: la penalització és inerta . . . 19

6.1.2 Rang alt d'α: *fairness-accuracy trade-off* 20
6.2 Codificació del gènere a la capa intermèdia 21
6.3 Comparació entre NIH ChestX-ray i CheXpert 22

7 Conclusions i treball futur **25**
7.1 Conclusions 25
7.2 Consideracions ètiques i legals 26
7.3 Treball futur 27

Bibliografia **29**

CAPÍTOL 1

Introducció

1.1 Context i motivació

L'aprenentatge profund ha experimentat un creixement extraordinari en el camp de la imatge mèdica durant l'última dècada. Els models basats en xarxes neuronals convolucionals (CNNs) han assolit resultats comparables o fins i tot superiors als clínics en tasques com la detecció de càncer de pell, la identificació de retinopatia diabètica o el diagnòstic de malalties pulmonars a partir de radiografies de tòrax. Tanmateix, l'aplicació d'aquests models en entorns clínics reals planteja qüestions ètiques fonamentals que van més enllà de la precisió diagnòstica.

Un d'aquests reptes és el biaix algorísmic: la tendència dels models d'aprenentatge automàtic a reproduir, i de vegades amplificar, desigualtats presents a les dades d'entrenament. En l'àmbit mèdic, això pot traduir-se en diferències en la qualitat del diagnòstic en funció del gènere, l'ètnia o altres atributs sensibles del pacient. Un sistema que diagnostica la pneumònia amb alta precisió per als homes però amb pitjors resultats per a les dones no és només menys precís: és intrínsecament injust i potencialment perjudicial.

Per abordar aquest problema s'han proposat diverses estratègies. Les tècniques de *pre-processing* actuen sobre les dades d'entrenament (per exemple, reequilibrant la representació dels grups); les de *post-processing* ajusten les prediccions a posteriori; i les d'*in-processing* intervenen directament durant l'entrenament, habitualment afegint un terme de penalització a la funció de pèrdua. En aquest treball s'adopta una aproximació d'*in-processing*: s'afegeix a la loss un terme que penalitza les diferències de predicció entre gèneres.

La hipòtesi de partida d'aquest treball és que **a l'hora de forçar el model a ser just, aquest necessita codificar activament el gènere del pacient en les seves representacions internes**. Per poder igualar el seu comportament entre grups, el model ha de "saber" a quin grup pertany cada pacient, i per tant el gènere emergeix a les capes de la xarxa com a conseqüència de la pròpia penalització. Paradoxalment, la restricció de *fairness* no eliminaria la codificació del gènere sinó que la podria incrementar respecte a un model no penalitzat.

1.2 Problema i qüestions de recerca

El biaix de gènere en models de diagnosi mèdica no és únicament un problema de rendiment: és un problema de *fairness*. Si el model presenta diferències significatives en la seva taxa de vertaders positius (TPR) entre homes i dones, pacients d'un gènere podran rebre diagnòstics incorrectes amb major freqüència que els de l'altre. Partint de la hipòtesi enunciada a la secció anterior, el treball formula tres qüestions de recerca:

1. **Codificació del gènere:** La informació de gènere queda codificada en les representacions intermèdies d'una CNN entrenada per detectar pneumònia, malgrat no haver estat introduïda explícitament al model? Per respondre aquesta pregunta s'utilitza la tècnica de *linear probing* (descrita a la Secció 2).

2. **Impacte de la capacitat de la xarxa:** La mida de la capa final de la xarxa influeix en la quantitat d'informació de gènere que el model és capaç de retenir a la penúltima capa? Aquesta capa és la que alimenta directament el classificador final: si el gènere no hi és codificat, el model no el pot fer servir per predir, independentment de si estava present en capes anteriors.

3. **Efecte de la penalització de *fairness*:** L'addició del terme de regularització incrementa la presència d'informació de gènere a les capes internes de la xarxa, com a conseqüència del fet que el model necessita distingir els grups per igualar el seu comportament?

1.3 Treballs relacionats i posicionament

El biaix en classificadors d'imatge mèdica ha estat objecte de recerca creixent en els darrers anys. El paper *CheXclusion* [Seyyed-Kalantari 2021] és el treball més directament relacionat amb aquest estudi: demostra l'existència de diferències sistemàtiques de TPR en classificadors profunds de radiografies de tòrax en funció del gènere i l'ètnia, i ho fa sobre els mateixos datasets emprats en aquest treball. Larrazabal et al. [Larrazabal 2020] analitzen com el desbalanceig de gènere al dataset d'entrenament amplifica el biaix i proposen el balanceig com a intervenció de *pre-processing*. Hardt et al. [Hardt 2016] formalitzen les nocions d'*equalized odds* i *equal opportunity*, que serveixen de marc teòric per a la restricció de *fairness* adoptada. Dang [Dang 2026] proposa un marc d'avaluació per capes per analitzar com atributs sensibles com l'edat o el tipus d'escàner queden codificats en les representacions internes de CNNs i Vision Transformers en el diagnòstic de l'Alzheimer per MRI, i com aquesta codificació influeix en l'equitat. Aquest treball constitueix el precedent metodològic més directe de l'anàlisi

realitzada en aquest estudi. La revisió d'aquests i d'altres treballs es desenvolupa en detall al Capítol 2.

Aquest treball es diferencia dels treballs existents en dos aspectes principals. En primer lloc, mentre la majoria d'estudis avaluen el biaix com a mètrica d'avaluació externa del model, aquí s'investiga explícitament com la informació de gènere queda codificada a les representacions *intermèdies* de la xarxa, analitzant-ne la decodificabilitat en sis punts de l'arquitectura mitjançant *linear probing*, tot i que el focus del treball és en la capa intermèdia densa (punt 6), just abans de la classificació final. A diferència de Dang [Dang 2026], es combina l'anàlisi per capes amb un *sweep* sistemàtic de la penalització de *fairness* i la mida de la capa, estudiant explícitament com la restricció d'*in-processing* altera la distribució de la informació de gènere al llarg de la xarxa. En segon lloc, es proposa un disseny experimental sistemàtic que explora la interacció entre la capacitat del model —determinada per la mida de la penúltima capa de la xarxa (ls)— i el grau de restricció de *fairness* (controlat per α), permetent identificar sota quines condicions la penalització és efectiva i a quin cost.

1.4 Contribucions

Les contribucions principals d'aquest treball consisteixen en respondre les preguntes de recerca plantejades:

- La informació de gènere present a les representacions intermèdies d'una CNN de diagnosi persisteix quan s'aplica una penalització de *fairness* basada en diferència de TPR?
- Com interactuen la mida de la capa intermèdia (ls) i el pes de la penalització (α) en la decodificabilitat del gènere a les representacions internes?
- Existeix un llindar crític d'α a partir del qual la penalització es torna efectiva, i quin és el cost en rendiment diagnòstic?

Per respondre-les, s'implementa un marc d'anàlisi basat en *linear probing* i un *sweep* sistemàtic sobre ls i α, avaluat als datasets NIH ChestX-ray i CheXpert. L'ús de la diferència de TPR com a mètrica de biaix segueix la metodologia de *CheXclusion* [Seyyed-Kalantari 2021], un estudi de referència en *fairness* en radiografies de tòrax.

Els principals resultats obtinguts són els següents:

- En el rang baix de penalització ($\alpha \in [0.2, 1.2]$), la restricció de *fairness* és pràcticament inerta: ni el biaix de gènere ni la codificació del gènere a les representacions intermèdies es veuen afectats de manera mesurable.

- En el rang alt ($\alpha \in [1, 1000]$), apareix un *fairness-accuracy trade-off* clar a partir d'un llindar crític ($\alpha \approx$ 25–50 al NIH; $\alpha \approx$ 10–25 al CheXpert), a partir del qual la reducció del biaix ve acompanyada d'una degradació severa de l'AUC diagnòstica.
- La mida de la capa intermèdia (ls) és el principal determinant de la decodificabilitat del gènere, per sobre del pes de la penalització α.
- Contràriament a la hipòtesi de partida, augmentar α no incrementa de manera rellevant la codificació del gènere a la capa intermèdia.

1.5 Estructura del document

La resta del document s'organitza de la manera següent. El Capítol 2 presenta l'estat de l'art en *fairness* en aprenentatge automàtic, biaix en models de diagnosi mèdica i mètodes d'anàlisi de representacions internes. El Capítol 3 introdueix el domini, els datasets emprats, l'arquitectura del model i les nocions de *fairness* i notació formals. El Capítol 4 descriu la metodologia i la planificació del projecte. El Capítol 5 detalla la contribució metodològica del treball. El Capítol 6 presenta els resultats experimentals obtinguts als quatre experiments de *sweep*. Finalment, el Capítol 7 resumeix les conclusions, avalua críticament els resultats, discuteix les consideracions ètiques i presenta les línies de treball futur.

CAPÍTOL 2

Estat de l'art

2.1 *Fairness* (justícia) en aprenentatge automàtic

La *fairness* en aprenentatge automàtic és un camp de recerca en ràpid creixement que estudia com garantir que els models no discriminin individus o grups definits en funció d'atributs sensibles (*protected attributes*) com el gènere, l'ètnia o l'edat [Barocas 2023]. Existeixen múltiples definicions matemàtiques de *fairness*, cadascuna capturant un aspecte diferent de l'equitat:

- **Paritat demogràfica (*Demographic Parity*):** La probabilitat de predicció positiva és igual per a tots els grups, independentment de si la predicció és correcta.
- **Igualtat d'oportunitats (*Equalized Odds*):** Les taxes de vertaders positius (TPR) i falsos positius (FPR) són iguals per a tots els grups.
- **Igualtat de la taxa de vertaders positius (*Equal TPR*):** Cas particular dels Equalized Odds que només considera la TPR, garantint que el model detecta la condició positiva amb la mateixa freqüència per a tots els grups.

La paritat demogràfica i les nocions d'igualtat d'oportunitats es discuteixen en detall a [Barocas 2023]. La definició formal d'*equalized odds* i la seva relaxació (*equal opportunity*) es deuen a Hardt et al. [Hardt 2016].

2.2 Biaix en models de diagnosi mèdica

El biaix en models d'aprenentatge profund (DL) aplicats a la medicina ha estat documentat en diversos dominis. Estudis han demostrat que models de diagnosi d'imatge mèdica poden presentar diferències significatives de rendiment en funció del gènere o l'ètnia, derivades principalment de desbalancejos al dataset d'entrenament o de correlacions espúries entre els atributs sensibles i les característiques rellevants per al diagnòstic [Larrazabal 2020].

En el cas concret de les radiografies de tòrax, el paper *CheXclusion* [Seyyed-Kalantari 2021] demostra l'existència de diferències sistemàtiques en la taxa de vertaders positius (TPR) de classificadors profunds en funció del gènere i l'ètnia,

analitzant diversos datasets incloent el NIH ChestX-ray. Aquest treball utilitza la diferència de TPR entre grups com a mètrica de biaix, la mateixa que s'adopta en aquest treball.

Factors anatòmics com la mida dels pulmons, la densitat del teixit gras i muscular o la presentació clínica de la pneumònia poden diferir entre homes i dones. Això implica que un model que aprengui a usar aquestes diferències per al diagnòstic podria estar indirectament codificant informació de gènere, fins i tot quan aquesta variable no és explícitament proporcionada com a entrada.

2.3 Anàlisi de representacions internes

Per estudiar quina informació queda codificada a les capes intermèdies d'una xarxa neuronal s'han proposat diverses tècniques:

- ***Linear probing*:** S'entrena un classificador lineal (típicament una regressió logística) a partir de les activacions de les neurones d'una capa per predir una propietat d'interès. La mètrica principal és l'AUC ROC del classificador: un valor proper a 0.5 indica que la informació no és linealment decodificable des d'aquella capa, mentre que un valor proper a 1.0 indica que hi és fortament codificada. Cal tenir en compte que el *linear probing* únicament detecta codificació *lineal*: si la informació estigués present però representada de manera no lineal, l'AUC podria ser propera a 0.5 malgrat que hi fos codificada. És la tècnica adoptada en aquest treball.

Existeixen altres tècniques per analitzar representacions que no s'han implementat en el marc actual però que podrien constituir línies de treball futur:

- **MMD (*Maximum Mean Discrepancy*):** Mesura la distància entre les distribucions de les representacions de dos grups sense necessitat d'entrenar cap model.

- **HSIC (*Hilbert-Schmidt Independence Criterion*):** Mesura la dependència estadística entre representacions i atributs en un espai de kernels, i pot ser usat tant com a mètrica d'anàlisi com directament com a terme de *loss* de disentanglement.

- **CKA (*Centered Kernel Alignment*):** Mesura la similitud entre representacions de dues xarxes o dues capes, invariant a transformacions ortogonals i d'escalat.

2.4 Mètodes de regularització per a *fairness*

Els mètodes de regularització per a *fairness* s'emmarca dins del que s'anomena *in-processing*: intervencions aplicades directament durant l'entrenament del model, en contrast amb els mètodes de *pre-processing* (que modifiquen les dades) i els de *post-processing* (que ajusten les prediccions a posteriori) [Barocas 2023].

Els enfocaments d'*in-processing* més habituals inclouen:

- **Regularització per penalització directa:** S'afegeix un terme a la funció de pèrdua que penalitza el biaix mesurat en cada *batch*. La penalització pot basar-se en diferència de TPR, diferència de probabilitats de predicció (*demographic parity loss*) o altres mètriques de disparitat. És l'estratègia adoptada en aquest treball.

- **Regularització adversarial:** S'entrena conjuntament el model principal i un discriminador que intenta predir l'atribut sensible (en el nostre cas, el gènere) a partir de les representacions intermèdies. L'objectiu és maximitzar el rendiment diagnòstic mentre es minimitza la capacitat del discriminador, induint representacions que no continguin informació de gènere.

- **Restriccions de *fairness*:** Formulació del problema d'entrenament com una optimització amb restriccions explícites sobre les mètriques de fairness, resoltes típicament amb mètodes de multiplicadors de Lagrange.

Un aspecte comú a tots aquests enfocaments és l'existència d'un *trade-off* entre rendiment diagnòstic i equitat, que a la literatura s'anomena *fairness-accuracy trade-off*: augmentar la restricció de *fairness* tendeix a reduir el biaix però sovint a costa de degradar l'AUC o d'altres mètriques de rendiment. Aquest compromís s'acostuma a visualitzar com un diagrama de dispersió on l'eix horitzontal representa el rendiment (p. ex. l'AUC diagnòstica) i el vertical el biaix (p. ex. el Gap TPR), de manera que cada punt correspon a una configuració del model [Barocas 2023].

En aquest treball s'utilitza la regularització per penalització directa basada en la diferència de TPR entre gèneres. Els detalls de la implementació diferenciable d'aquesta mètrica es descriuen al Capítol 5.

CAPÍTOL 3

Preliminars

3.1 Domini: pneumònia i radiografia de tòrax

La pneumònia és una infecció del parènquima pulmonar que provoca la inflamació dels alvèols, que s'omplen de fluid o de pus [World Health Organization 2024]. És una de les principals causes de mortalitat a nivell mundial, especialment en nens i persones grans. El diagnòstic clínic es basa en l'examen físic, l'anàlisi de símptomes i, sovint, la radiografia de tòrax (RX de tòrax).

En una RX de tòrax, la pneumònia es manifesta típicament com una opacificació o consolidació del teixit pulmonar en una zona concreta. La interpretació d'aquest tipus d'imatge requereix experiència clínica, i la detecció automatitzada mitjançant CNN ha estat objecte de recerca intensa en els darrers anys [Wang 2017].

3.2 Datasets emprats

La pipeline implementada en aquest treball és genèrica: accepta qualsevol dataset que proporcioni una taula de metadades de pacients (amb columnes d'imatge, etiqueta de classe i gènere) i una carpeta d'imatges corresponent. S'han emprat principalment dos datasets:

3.2.1 NIH ChestX-ray

El dataset NIH ChestX-ray [Wang 2017] és un conjunt de dades públic alliberat pel National Institutes of Health (NIH) dels Estats Units. Conté més de 100.000 radiografies de tòrax etiquetades amb catorze patologies pulmonars, extretes de l'arxiu clínic del NIH Clinical Center. Cada imatge inclou metadades com el gènere i l'edat del pacient. És el dataset principal d'aquest treball, usat en tots els experiments inicials.

Per a aquest treball s'han seleccionat únicament les imatges etiquetades com a *Pneumonia* o *No Finding*, reduint el problema a una classificació binària. El dataset presenta un desbalanceig natural tant per classe (la classe positiva és minoritària) com per subgrup (class × gènere), circumstància que s'ha de tenir en compte tant en l'entrenament com en l'avaluació.

Les imatges es preprocessen de la manera següent:

1. Filtrat per retenir únicament les classes d'interès (*Pneumonia* i *No Finding*).
2. Redimensionat a 224 × 224 píxels (mida estàndard per a models pre-entrenats amb ImageNet).
3. Conversió a format RGB de tres canals (tot i que les radiografies originals són en escala de grisos, el model pre-entrenat requereix imatges en color).
4. Normalització amb les estadístiques estàndard d'ImageNet (mitjana i desviació típica per canal).
5. Divisió en conjunts de train, validació i test, estratificada per classe.

3.2.2 CheXpert

CheXpert és un dataset públic de radiografies de tòrax alliberat per Stanford University [Irvin 2019]. Conté més de 200.000 imatges amb etiquetes per a catorze patologies, incloent metadades de gènere. L'accés es realitza sota un Data Use Agreement (DUA) de Stanford University que restringeix l'ús a fins de recerca no comercial i prohibeix la redistribució de les dades. S'ha incorporat als experiments posteriorment al NIH ChestX-ray, aplicant el mateix pipeline de preprocessament i la mateixa metodologia d'anàlisi.

3.2.3 Altres datasets considerats

Durant el desenvolupament del treball es va considerar també l'ús del dataset MIMIC-CXR (PhysioNet), que és una altra font important de radiografies de tòrax amb metadades de gènere i ètnia. No ha estat possible accedir-hi perquè l'obtenció de les credencials d'accés requereix la superació del curs d'ètica de la recerca del CITI Program (*Collaborative Institutional Training Initiative*), un curs de pagament per al qual la Universitat de Girona no disposa d'un acord institucional en el moment de realitzar aquest treball. L'ús de MIMIC-CXR queda com a línia de treball futur.

3.3 Model: ResNet18

La ResNet18 (*Residual Network* de 18 capes) és una arquitectura CNN proposada per He et al. [He 2016] que va revolucionar el camp de la visió per computador gràcies a l'ús de connexions residuals (*skip connections*), que permeten entrenar

xarxes molt profundes sense patir el problema del gradient evanescent (*vanishing gradient*).

En aquest treball s'utilitza una ResNet18 pre-entrenada amb el dataset ImageNet. Les últimes capes de classificació (fully connected) es substitueixen per una nova capa densa configurable de mida *last_layer_size*, seguida d'una capa de sortida de dues neurones (pneumònia / no pneumònia). Els pesos de la ResNet18 pre-entrenada es mantenen congelats durant l'entrenament: només s'actualitzen els paràmetres de la capa densa intermèdia i la capa de classificació afegides. Aquesta estratègia aprofita les representacions visuals apreses en ImageNet i centra l'aprenentatge en les noves capes.

L'entrenament combina dues components de pèrdua: la pèrdua d'entropia creuada ($\mathscr{L}_{CE}$), que garanteix el rendiment diagnòstic, i la pèrdua de *fairness* ($\mathscr{L}_{fair}$), que penalitza les diferències de predicció entre gèneres. El paràmetre $\alpha \geq 0$ controla el pes relatiu de la penalització: $\alpha = 0$ produeix un model estàndard sense cap restricció de *fairness*, mentre que valors creixents d'α incrementen progressivament el cost del biaix. La pèrdua total és $\mathscr{L}_{total} = \mathscr{L}_{CE} + \alpha \cdot \mathscr{L}_{fair}$ (Equació 3.3).

3.4 Nocions de *fairness* emprades

3.4.1 Taxa de vertaders positius (TPR)

La taxa de vertaders positius (TPR), també anomenada *recall* o sensibilitat, es defineix per a un grup g com:

$$\mathrm{TPR}_g = \frac{\mathrm{TP}_g}{\mathrm{TP}_g + \mathrm{FN}_g} \tag{3.1}$$

on TP_g és el nombre de vertaders positius i FN_g el nombre de falsos negatius per al grup g.

3.4.2 Penalització de *fairness* basada en TPR

La penalització de *fairness* emprada en aquest treball es basa en minimitzar la diferència en la probabilitat de predicció positiva entre els dos grups de gènere. Aquesta mesura actua com a *proxy* de la diferència de TPR: calculada únicament sobre les mostres positives del batch ($y = 1$), és equivalent a comparar les taxes de predicció positiva correcta entre gèneres. Formalment, per a un batch d'entrenament, la fairness loss es defineix com:

$$\mathscr{L}_{fair} = (\bar{p}_{homes} - \bar{p}_{dones})^2 \tag{3.2}$$

on $\bar{p}_{homes}$ i $\bar{p}_{dones}$ són les probabilitats de predicció positiva mitjanes calculades únicament sobre les mostres positives ($y = 1$) del batch, per al grup d'homes i de dones respectivament.

La funció de pèrdua total és:

$$\mathscr{L}_{total} = \mathscr{L}_{CE} + \alpha \cdot \mathscr{L}_{fair} \tag{3.3}$$

on $\alpha \geq 0$ és un hiperparàmetre que controla el pes relatiu de la penalització. Quan $\alpha = 0$ el model s'entrena sense restricció de *fairness*; a mesura que α augmenta, el model és penalitzat amb major intensitat per les diferències de predicció entre gèneres.

CAPÍTOL 4

Planificació i Metodologia

4.1 Metodologia general

El projecte segueix una metodologia iterativa pròpia de la ciència de dades. El punt de partida és un script experimental que implementa el pipeline bàsic d'entrenament amb penalització de *fairness* i l'extracció de representacions intermèdies. A partir d'aquest codi base, s'han realitzat les passes següents:

1. **Comprensió i refactorització del codi base:** Anàlisi detallada de l'script original, estudi de l'arquitectura ResNet18 modificada i dels mecanismes de càlcul del gradient.

2. **Exploració inicial:** Entrenaments amb hiperparàmetres estàndard per verificar el comportament del model (sobreajust, convergència, etc.).

3. **Disseny del sweep experimental:** Definició de la graella d'experiments (combinacions de *last_layer_size* $\times$ α) per explorar de manera sistemàtica l'espai de configuracions.

4. **Execució del sweep:** Entrenament de tots els models de la graella i emmagatzematge dels resultats.[1]

5. **Anàlisi de representacions:** Extracció de les representacions intermèdies de cada model entrenat i aplicació del *linear probing* per a cada capa.

6. **Anàlisi de resultats:** Visualització i interpretació dels resultats en termes de biaix de gènere i decodificabilitat.

Al llarg de tot el treball s'han mantingut reunions setmanals amb el tutor per videotrucada, en les quals es comentava l'estat del projecte, es discutien els resultats dels experiments en curs i es prenien decisions sobre els passos següents. Aquesta dinàmica iterativa ha estat fonamental per orientar l'anàlisi i interpretar correctament les troballes.

[1] Els experiments del sweep s'han executat fent ús dels recursos computacionals (GPU) posats a disposició pel grup de recerca GILAB de la Universitat de Girona.

4.2 Planificació temporal

El treball s'ha desenvolupat en tres etapes principals:

1. **Fase inicial — comprensió del problema (primers mesos):** Aquesta fase va requerir un esforç crucial per familiaritzar-se amb el problema plantejat i el marc teòric de la *fairness* en imatge mèdica. La comprensió de la interacció entre la penalització de *fairness*, l'arquitectura del model i les mètriques d'avaluació va ser gradual.

2. **Fase de refinament i execució (mesos centrals):** Un cop establerta la base, es va dissenyar la graella experimental, es van executar els sweeps i es van anar analitzant els resultats en paral·lel. Una limitació important d'aquesta fase va ser el temps d'execució dels experiments: cada sweep complet requeria entre dos i tres dies amb la infraestructura de la universitat. Això va dificultar la cadència d'iteració i va implicar que, en algunes reunions setmanals amb el tutor, els resultats disponibles fossin incomplets. Alguns dels sweeps inicials, amb un nombre de repeticions o una graella d'hiperparàmetres menys consolidada, es van descartar i no es presenten als resultats finals.

3. **Fase de redacció (darreres dues setmanes):** Redacció de la memòria, revisió dels resultats i tancament del document.

4.3 Costos de realització

Els experiments s'han executat a les GPU del grup GILAB de la Universitat de Girona. Els conjunts de dades emprats (NIH ChestX-ray i CheXpert) són públics i d'accés gratuït per a fins de recerca.

4.4 Pipeline d'entrenament

El pipeline d'entrenament implementat en PyTorch consta dels elements principals següents:

- **Dataset:** `ChestXrayDataset`, una classe que retorna tres dades (imatge, etiqueta de classe i etiqueta de gènere) per a cada mostra.

- **Model:** ResNet18 pre-entrenada amb les últimes capes substituïdes per una capa densa de mida *last_layer_size* i una capa de sortida de dos neurones.

- **Funció de pèrdua:** Combinació d'entropia creuada i fairness loss tal com es descriu a l'Equació 3.3.
- **Reproductibilitat:** Fixació de totes les llavors aleatòries (Python, NumPy, PyTorch, CUDA) per garantir la reproductibilitat dels experiments.

4.5 Disseny del sweep experimental

El sweep experimental explora la interacció entre dos hiperparàmetres principals:

- ***last_layer_size* (ls):** Mida de la capa densa intermèdia (la penúltima capa de la xarxa). Controla la capacitat del coll d'ampolla de la xarxa, i per tant la quantitat d'informació que pot fluir fins a la capa de classificació.
- **α:** Pes de la penalització de *fairness*. A mesura que α augmenta, el cost d'exhibir biaix de gènere durant l'entrenament creix.

Es van dissenyar dos sweeps de configuració diferent, aplicats en paral·lel sobre els dos datasets (NIH ChestX-ray i CheXpert), per explorar dos règims de penalització:

- **Rang baix d'α (experiments E1 i E2):** $\alpha \in \{0.2, 0.4, 0.6, 0.8, 1.0, 1.2\}$ (6 valors) i ls $\in \{4, 8, 12, 16, 20, 24, 28, 32, 48\}$ (9 valors). Permet verificar si penalitzacions petites ja indueixen efectes mesurables sobre el biaix i la codificació del gènere.
- **Rang alt d'α (experiments E3 i E4):** $\alpha \in \{1, 2.5, 5, 7.5, 10, 25, 50, 75, 100, 250, 500, 750, 1000\}$ (13 valors) i ls $\in \{2, 4, 6, 8\}$ (4 valors). El rang és deliberadament ampli per determinar si existeix un llindar a partir del qual la penalització es torna efectiva i per observar el comportament del model en condicions de penalització extrema.

Per a cada combinació (ls, α), s'entrenen 20 models amb llavors aleatòries independents i se n'agreguen els resultats (mitjana i desviació típica). Aquesta repetició proporciona estimacions robustes de: la pèrdua d'entrenament i validació, l'AUC diagnòstica, la diferència de TPR entre gèneres, i l'AUC del classificador de gènere per a cadascun dels sis punts d'extracció analitzats. El total de runs per sweep és $9 \times 6 \times 20 = 1080$ per als experiments E1/E2 i $4 \times 13 \times 20 = 1040$ per als experiments E3/E4.

CAPÍTOL 5

Contribució Metodològica

5.1 Regularització de *fairness* basada en diferència de TPR

Durant el desenvolupament del treball es van considerar diverses funcions de penalització de *fairness*: paritat demogràfica, *equalized odds* i regularització basada en independència estadística (HSIC). Finalment es va optar per la penalització basada en diferència de TPR, tant per la seva alineació amb la mètrica d'avaluació principal com pel seu precedent en la literatura de *fairness* en imatge mèdica.

La regularització de *fairness* implementada actua directament sobre el procés d'optimització: en cada pas d'entrenament, el gradient total incorpora un terme que penalitza la diferència de probabilitats de predicció entre gèneres. L'actualització dels pesos es realitza una sola vegada a partir del gradient de la *loss* total ($\mathscr{L}_{total}$). Per a fins de monitorització, s'executen dues passades enrere (*backward*) separades per registrar les normes del gradient de $\mathscr{L}_{CE}$ i de $\mathscr{L}_{total}$ per separat, la qual cosa permet diagnosticar la magnitud relativa del terme de penalització al llarg de l'entrenament.

CAPÍTOL 6

Resultats

Els resultats presentats en aquest capítol provenen de quatre experiments de sweep sistemàtic (Taula 6.1). Els dos primers cobreixen un rang baix de penalització ($\alpha \in [0.2, 1.2]$) sobre el NIH ChestX-ray i el CheXpert; els dos darrers exploren un rang molt més ampli ($\alpha \in [1, 1000]$) per determinar si existeix algun llindar a partir del qual la penalització es torna efectiva. Prèviament a aquests quatre experiments s'han realitzat experiments exploratoris addicionals amb un nombre reduït de repeticions i graelles d'hiperparàmetres menys consolidades, que han servit per validar el pipeline i orientar el disseny final dels sweeps però que no es presenten en detall per no ser comparables metodològicament amb els experiments principals.

Una pregunta transversal que articula la interpretació dels resultats és si el model *necessita* codificar el gènere per funcionar bé, o si simplement ho fa perquè té la capacitat de fer-ho. El disseny experimental aborda aquesta qüestió limitant la capacitat del model a través del paràmetre ls: una capa molt petita (per exemple, ls $= 8$) restringeix físicament la quantitat d'informació que pot ser retinguda fins al final de la xarxa, cosa que permet aïllar si el gènere és estrictament necessari per al diagnòstic o simplement accessible.

Exp.	**Dataset**	**Rang α**	**Valors *ls***	**Runs**
E1	NIH ChestX-ray	[0.2, 1.2]	4–48	1080
E2	CheXpert	[0.2, 1.2]	4–48	1080
E3	NIH ChestX-ray	[1, 1000]	2–8	1040
E4	CheXpert	[1, 1000]	2–8	1040

Taula 6.1: Resum dels quatre experiments analitzats. Per a cada combinació (ls, α), s'han entrenat 20 models amb llavors aleatòries independents.

6.1 Rendiment diagnòstic i biaix de gènere

6.1.1 Rang baix d'α: la penalització és inerta

Les Figures 6.1–6.4 segueixen la mateixa estructura de tres panells: **esquerra**, AUC del classificador de gènere a l'última capa vs. Gap TPR (±desv. est.); **centre**,

mateixa relació amb línies que connecten els valors de *ls* per a un α fix; **dreta**, AUC diagnòstica vs. Gap TPR. Aquest darrer panell és el visualment estàndard en la literatura de *fairness* per representar el *fairness-accuracy trade-off* [Barocas 2023].

En el rang $\alpha \in [0.2, 1.2]$, la penalització de *fairness* no produeix cap efecte mesurable. La Figura 6.1 (panell dret) mostra que tots els punts s'acumulen en una banda quasi vertical (AUC $\in [0.858, 0.862]$): les sis condicions d'α se superposen completament i el Gap TPR oscil·la entre 0.035 i 0.050 sense correlació amb α.

El panell esquerre de la mateixa figura mostra que l'AUC de gènere varia entre 0.50 i 0.90, però impulsada quasi exclusivament per *ls*: els punts es diferencien per símbol (un per valor de *ls*), mentre que punts del mateix *ls* amb α diferent estan completament solapats. En aquest règim, α no mou ni el biaix ni la codificació del gènere.

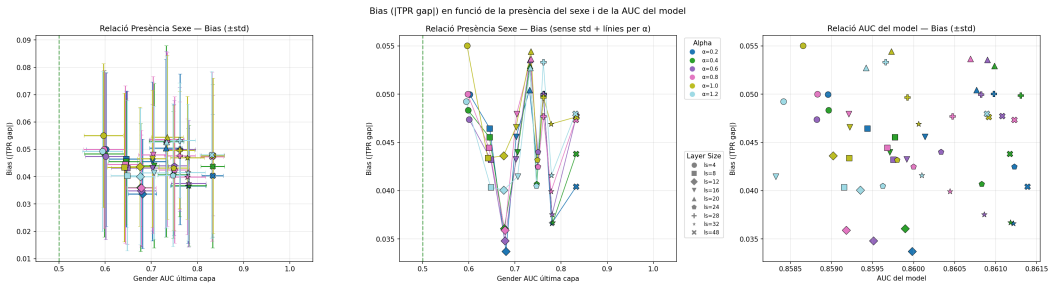


Figura 6.1: Experiment E1: NIH ChestX-ray, $\alpha \in [0.2, 1.2]$. Les condicions d'α se superposen en tots els panells: la penalització és inerta en aquest rang.

6.1.2 Rang alt d'α: *fairness-accuracy trade-off*

En el rang $\alpha \in [1, 1000]$ apareix un *fairness-accuracy trade-off* clar. La Figura 6.2 (panell dret) mostra com, a mesura que α augmenta, l'AUC diagnòstica disminueix i el Gap TPR s'aproxima a zero. Per a $\alpha = 1$, el model assoleix una AUC de 0.857 amb un Gap TPR de 0.050; per a $\alpha = 50$, l'AUC cau a 0.682 i el gap es redueix a 0.010; per a $\alpha = 1000$, l'AUC és de 0.525 i el gap és de 0.007.

La reducció del biaix no és lineal: la caiguda més pronunciada del Gap TPR ocorre entre $\alpha = 10$ i $\alpha = 50$, que és precisament la zona on l'AUC diagnòstica comença a degradar-se de forma accelerada (de 0.833 a 0.682). Per sobre de $\alpha = 50$, la millora en equitat és mínima (el gap passa de 0.010 a 0.007) mentre l'AUC continua deteriorant-se fins a nivells propers al classificador aleatori. Això evidencia l'existència d'un llindar crític al voltant de $\alpha \approx 25$–50 a partir del qual la penalització es torna efectiva, però a un cost diagnòstic sever.

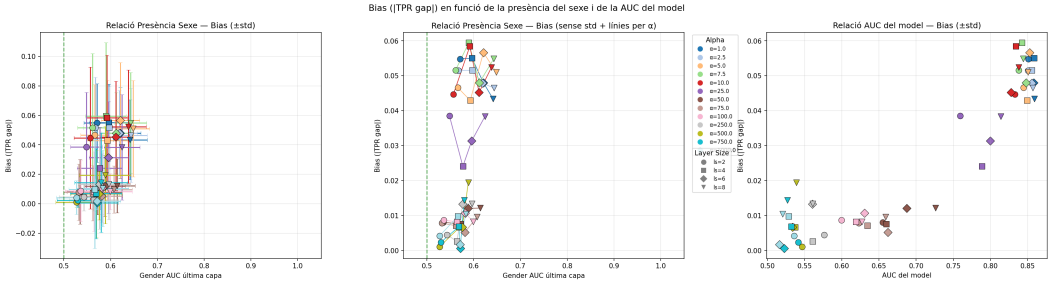


Figura 6.2: Experiment E3: NIH ChestX-ray, $\alpha \in [1, 1000]$. El panell dret evidencia el *trade-off*: α creixent desplaça els punts de dalt-dreta (alta AUC, alt biaix) cap a baix-esquerra (baixa AUC, baix biaix).

Patrons no monòtons al panell central. Tant a E1 com a E3 s'observa, al panell central, que el biaix no creix de manera monòtona en augmentar ls: en lloc d'això, els valors oscil·len de forma aparentment irregular. Aquest comportament és consistent amb la presència de variabilitat residual entre execucions: tot i haver fixat totes les llavors aleatòries disponibles (Python, NumPy, PyTorch i CUDA). Es manifesta com una dispersió no atribuïble als hiperparàmetres.

6.2 Codificació del gènere a la capa intermèdia

El panell esquerre de les Figures 6.1 i 6.2 mostra la relació entre l'AUC del classificador de gènere a l'última capa i el Gap TPR. Dos patrons ressalten en l'anàlisi conjunta dels quatre experiments:

Persistència de la informació de gènere. Les capes del backbone (post-maxpool, layer1, layer2, layer3, avgpool) presenten AUC de gènere de 1.0 en totes les condicions testades, independentment d'α i ls. Això confirma que el ResNet18 congelat codifica el gènere de manera perfectament lineal i que la penalització de *fairness* no hi pot actuar. A la capa intermèdia densa, l'AUC decreix lleugerament en augmentar α (especialment per a ls baix): per a $\alpha = 1000$ i ls $= 2$, arriba a 0.50, mentre que per a ls $= 8$ es manté a 0.595. En condicions normals d'operació (ls ≥ 12, $\alpha \leq 50$), l'AUC de gènere a la capa intermèdia roman entre 0.55 i 0.83.

Efecte de la mida de capa. En tots els experiments, *ls* és el principal determinant de l'AUC de gènere a l'última capa. Augmentar *ls* incrementa de forma monòtona la decodificabilitat: de ≈ 0.60 per a $ls = 4$ fins a ≈ 0.83 per a $ls = 48$ al NIH (experiment E1). Una capa més ampla té més capacitat per retenir la

informació de gènere procedent del backbone, però, un cop s'aplica la penalització amb α alt, aquesta capacitat addicional no es tradueix en biaix addicional: en el panell central de la Figura 6.2, les línies de α elevat convergeixen en valors de gap baixos independentment de *ls*. Els valors baixos de ls (ls ≤ 8 als experiments E3 i E4) s'inclouen intencionadament per estressar el model i forçar-lo a prioritzar la informació que reté: sense penalització, s'esperava que descartés el gènere per irrellevant; amb penalització alta, que l'hagués de mantenir per poder ser just. Al NIH, el rendiment diagnòstic es veu poc afectat per ls (excepte per a ls $= 4$), cosa que confirma que la restricció de capacitat no compromet la tasca principal.

6.3 Comparació entre NIH ChestX-ray i CheXpert

Les Figures 6.3 i 6.4 mostren els resultats equivalents per al dataset CheXpert.

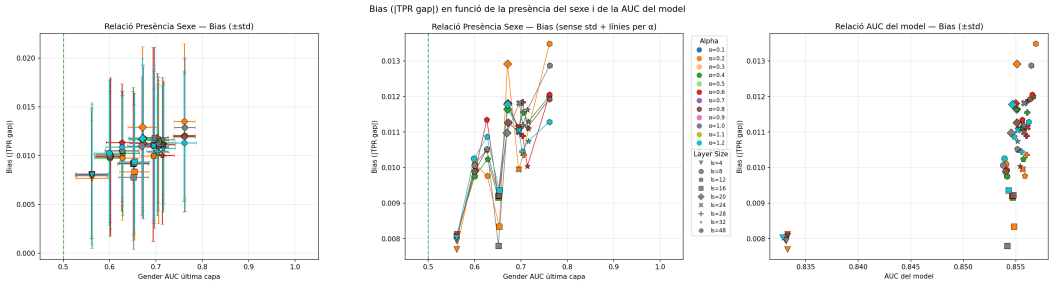


Figura 6.3: Experiment E2 (CheXpert, $\alpha \in [0.2, 1.2]$, 20 runs/config). El panell dret mostra totes les configuracions concentrades en una banda quasi vertical (AUC $\in [0.835, 0.855]$) amb un biaix de partida molt baix (≈ 0.010). Com a l'experiment E1, α és completament inert en aquest rang.

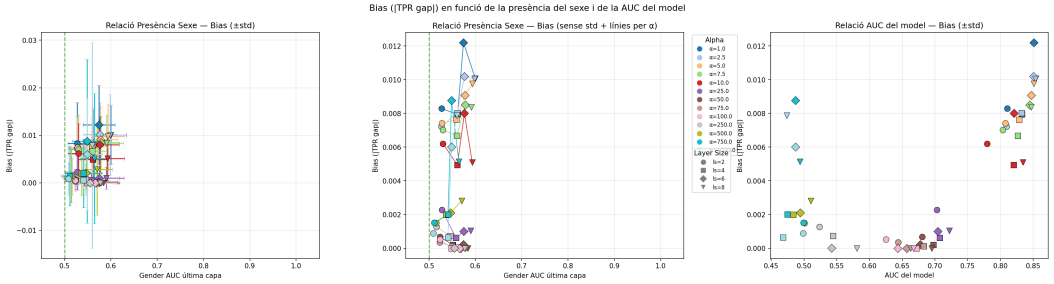


Figura 6.4: Experiment E4 (CheXpert, $\alpha \in [1, 1000]$, 20 runs/config). El panell dret mostra el mateix *trade-off* monòton que per al NIH, però amb un biaix de partida quatre vegades inferior. L'AUC de gènere (panell esquerre) és sistemàticament més baixa que per al NIH, situant-se entre 0.49 i 0.66.

La comparació entre els dos datasets revela diferències quantitatives importants que mantenen el mateix patró qualitatiu:

- **Biaix de partida.** CheXpert presenta un Gap TPR inicial (a $\alpha = 1$) de 0.010, aproximadament quatre vegades inferior al del NIH (0.050). Això suggereix que la composició demogràfica i la naturalesa de les etiquetes de CheXpert generen menys biaix de gènere intrínsec.
- **Llindar crític d'α.** Al CheXpert, la reducció significativa del biaix s'inicia a $\alpha \approx 10$–25 (el gap passa de 0.006 a 0.001), mentre que al NIH el llindar és $\alpha \approx 25$–50. L'equitat de facto s'assoleix amb penalitzacions menors al CheXpert, probablement perquè el biaix a corregir és menys profundament arrelat en la distribució de les dades.
- **Codificació del gènere.** L'AUC de gènere a l'última capa és sistemàticament 0.05–0.07 unitats inferior al CheXpert que al NIH en condicions comparables (≈ 0.57 vs ≈ 0.61 a $\alpha = 1$ en el rang alt). La informació de gènere és menys linealment accessible en les representacions que el backbone extreu d'aquest dataset, però persisteix per sobre de 0.50 en tots els casos.
- **Cost en rendiment diagnòstic.** La degradació de l'AUC diagnòstica segueix una corba similar en ambdós datasets. Per a $\alpha = 10$, l'AUC és 0.833 al NIH i 0.814 al CheXpert; per a $\alpha = 50$, és 0.682 i 0.688 respectivament. El cost de la penalització sobre la qualitat del diagnòstic és comparable entre els dos conjunts de dades.

Patrons específics al CheXpert, rang baix (E2). El panell dret de la Figura 6.3 revela un efecte notable de la mida de capa sobre el rendiment diagnòstic: les configuracions amb ls $= 4$ presenten una caiguda sobtada d'aproximadament 0.02 unitats d'AUC respecte a la resta (que es concentren totes a AUC $\in [0.853, 0.857]$), de manera independent d'α. Aquesta disminució és atribuïble a la compressió extrema que imposa una capa tan petita sobre la representació. El panell esquerre de la mateixa figura revela, a més, una tendència positiva entre l'AUC de gènere a la capa intermèdia i el Gap TPR: a major presència de gènere a les representacions, major biaix. Tanmateix, el rang molt estret de biaixos en aquest dataset (Gap TPR $\in [0.008, 0.014]$) limita la força d'aquesta relació i en dificulta la interpretació.

Patrons específics al CheXpert, rang alt (E4). La Figura 6.4 (panell dret) evidencia, de manera molt més clara que al NIH, la transició qualitativa del model en creuar el llindar crític d'α: hi ha un punt ben definit a partir del qual els

experiments passen abruptament de la zona d'alta AUC i biaix moderat cap a la zona de baixa AUC i biaix proper a zero. A partir d'$\alpha \approx 10$–25, el model abandona la tasca diagnòstica i concentra l'optimització en la igualació de prediccions entre gèneres. Un fenomen addicional apareix per als valors d'α més extrems ($\alpha \geq 500$), on l'AUC diagnòstica ronda el 0.5: el biaix, en lloc de continuar decreixent, torna a incrementar-se lleugerament. Una explicació plausible és que, quan el model opera en règim pràcticament aleatori, les seves prediccions deixen de reflectir característiques apreses i la diferència de TPR queda dominada per la variança de mostreig sobre la distribució de classe $\times$ gènere del conjunt de test.

CAPÍTOL 7

Conclusions i treball futur

7.1 Conclusions

Aquest treball ha estudiat com la informació de gènere queda codificada en les representacions intermèdies d'una CNN entrenada per detectar pneumònia, i com aquesta codificació canvia en aplicar una restricció de *fairness* durant l'entrenament. A partir dels quatre experiments de *sweep* sistemàtic realitzats, es deriven les conclusions principals següents.

La penalització de *fairness* és inerta en el rang baix d'α. En els experiments E1 i E2, amb $\alpha \in [0.2, 1.2]$, la penalització no produeix cap efecte mesurable ni sobre el biaix de gènere ni sobre la decodificabilitat del gènere a les representacions intermèdies. Totes les configuracions d'α es solapen completament en ambdós panells de dispersió, i la variabilitat observada és atribuïble quasi exclusivament a la mida de la capa intermèdia. Existeix, per tant, un llindar mínim per sota del qual el senyal de la penalització no és prou fort per alterar la dinàmica d'optimització del model.

A valors elevats d'α, el model experimenta una transició qualitativa. En els experiments E3 i E4, amb $\alpha \in [1, 1000]$, apareix un *fairness-accuracy trade-off* clar. El llindar crític se situa al voltant de $\alpha \approx 25$–50 per al NIH ChestX-ray i $\alpha \approx 10$–25 per al CheXpert. A partir d'aquest punt, el model deixa de prioritzar el diagnòstic i passa a focalitzar-se en la igualació de prediccions entre gèneres, amb una caiguda accelerada de l'AUC diagnòstica fins a nivells propers al classificador aleatori. Especialment visible en les corbes del CheXpert, aquest canvi de comportament és abrupte: fins al llindar el model és un classificador competent amb biaix moderat; a partir d'ell, la penalització domina l'optimització i el rendiment diagnòstic es col·lapsa.

La mida de la capa intermèdia és el principal determinant de la decodificabilitat del gènere. El paràmetre ls domina la variabilitat de l'AUC de gènere en tots els experiments, per sobre de l'efecte de α. Augmentar ls incrementa de forma monòtona la capacitat de la capa per retenir la informació de gènere procedent del *backbone*. Els valors molt baixos de ls (per exemple, ls ≤ 8)

constitueixen casos extrems que comprimeixen artificialment la representació fins al punt de comprometre el rendiment diagnòstic de manera independent d'α: al CheXpert, reduir ls a 4 provoca una caiguda sobtada d'aproximadament 0.02 unitats d'AUC respecte a la resta de configuracions. Aquests valors s'inclouen en el disseny per explorar el comportament límit del sistema, però no es corresponen amb configuracions d'ús pràctic. Cal assenyalar, com a observació addicional, que en cap de les condicions testades l'AUC de gènere a la capa intermèdia no cau per sota de 0.50 de manera consistent, cosa coherent amb el fet que el *backbone* congelat ja codifica el gènere de manera perfecta i independent de la penalització.

Diferències entre NIH ChestX-ray i CheXpert. CheXpert presenta un biaix de gènere intrínsec considerablement inferior al del NIH (Gap TPR de partida de 0.010 vs. 0.050), i la informació de gènere és menys linealment accessible en les seves representacions. Tot i això, els patrons qualitatius es reprodueixen en ambdós datasets. Al CheXpert s'observa una relació positiva entre l'AUC de gènere a la capa intermèdia i el Gap TPR: a major presència de gènere a les representacions, major biaix. Tanmateix, el rang molt limitat de biaixos d'aquest dataset redueix la força d'aquesta relació i en dificulta la interpretació.

Els resultats confirmen parcialment la hipòtesi central del treball. La informació de gènere persisteix a les representacions intermèdies fins i tot amb una penalització intensa, però no s'observa un increment net i consistent de la seva codificació en funció d'α.

D'altra banda, els patrons observats als panells centrals dels experiments E1 i E3 (biaix pujant i baixant de manera no monòtona en augmentar ls) reflecteixen la variabilitat estadística inherent al procés d'optimització estocàstic. Les 20 repeticions per configuració proporcionen estimacions robustes de les mètriques principals, però la variança residual entre inicialitzacions fa que les tendències fines no siguin perfectament suaus. Augmentar el nombre de repeticions suavitzaria aquestes fluctuacions.

7.2 Consideracions ètiques i legals

El treball planteja diverses qüestions ètiques i legals rellevants per al desplegament de sistemes d'intel·ligència artificial en diagnosi mèdica.

La primera és la **paradoxa de la *fairness* i la privacitat**. Els mètodes d'*in-processing* com el d'aquest treball requereixen que el gènere del pacient sigui disponible durant l'entrenament. Això pot entrar en tensió amb la normativa de protecció de dades (el RGPD a Europa), que limita el tractament de dades sensibles. A més, introduir explícitament el gènere en el procés d'optimització

pot ser interpretat, en alguns marcs legals, com una forma de discriminació directa, fins i tot quan l'objectiu és precisament reduir-ne la disparitat.

La segona és el ***fairness-accuracy trade-off***. Els resultats mostren que reduir el biaix de gènere a nivells baixos requereix sacrificar de manera significant la qualitat diagnòstica. La decisió de quin equilibri és acceptable no és una decisió tècnica sinó de valor, i hauria d'involucrar metges, pacients i reguladors. Un sistema que diagnostica amb menor precisió per ser formalment just pot causar un dany net superior a un sistema eficaç però amb biaix moderat, depenent del context clínic i de la gravetat de les patologies en joc.

Finalment, cal tenir en compte la **responsabilitat sobre la decisió clínica**. Un model de diagnosi és un sistema de suport, no un agent decisor. La incorporació de restriccions de *fairness* no elimina la responsabilitat del professional sanitari sobre el diagnòstic final. En qualsevol desplegament real, caldria documentar explícitament les limitacions del model i el valor d'α adoptat, de manera que els usuaris clínics puguin interpretar les prediccions coneixent les propietats de rendiment per subgrup.

Tot i que les dades són públiques i han estat de-identificades pels custodis originals per protegir la privacitat dels pacients, és important reconèixer que datasets biomèdics poden contenir informació quasi-identificable.

7.3 Treball futur

Les línies de treball futur identificades durant el desenvolupament del projecte inclouen:

- **Estratificació per (class × gènere):** L'split actual únicament estratifica per classe. Estratificar per (classe × gènere) garantiria una distribució equitativa de subgrups entre train, validació i test.

- **Gestió del desbalanceig de subgrups:** L'ús de `WeightedRandomSampler` per equilibrar els subgrups (classe × gènere) en l'entrenament podria millorar la qualitat de la penalització de *fairness*.

- **Mètodes alternatius d'anàlisi de representacions:** Explorar MMD, HSIC, CKA o informació mútua com a alternatives o complements al *linear probing* (el qual únicament detecta codificació lineal).

- **Altres datasets i atributs sensibles:** Ampliar l'anàlisi a altres conjunts de dades de radiografies (potencialment d'altres patologies) i a altres atributs sensibles com l'ètnia o l'edat. Una pregunta d'interès seria si l'efecte d'α

sobre el biaix depèn del biaix intrínsec del dataset: els dos datasets estudiats presenten un biaix de gènere baix; caldria avaluar si el comportament és diferent en datasets amb una disparitat inicial més pronunciada.

- **Accés al dataset MIMIC-CXR:** L'ús del dataset MIMIC-CXR (PhysioNet) permetria ampliar l'anàlisi a una cohort amb major diversitat demogràfica. L'accés requereix superar el curs d'ètica de CITI Program, que és de pagament per a universitats sense conveni amb aquesta iniciativa (cas de la UdG), motiu pel qual no ha estat possible en el marc d'aquest treball.
- **Data augmentation:** Aplicar augmentació de dades de manera que preservi l'equilibri entre subgrups (classe × gènere) per millorar la robustesa de l'entrenament.

Bibliografia

[Barocas 2023] Solon Barocas, Moritz Hardt and Arvind Narayanan. Fairness and Machine Learning: Limitations and Opportunities. MIT Press, 2023. (Cited on pages 5, 7 and 20.)

[Dang 2026] Ngoc Vien Dang. *Advances in Fairness Analysis in Artificial Intelligence for Healthcare*. PhD thesis, Universitat de Barcelona, 2026. (Cited on pages 2 and 3.)

[Hardt 2016] Moritz Hardt, Eric Price and Nati Srebro. *Equality of Opportunity in Supervised Learning*. In Advances in Neural Information Processing Systems (NeurIPS), volume 29, pages 3323–3331, 2016. (Cited on pages 2 and 5.)

[He 2016] Kaiming He, Xiangyu Zhang, Shaoqing Ren and Jian Sun. *Deep Residual Learning for Image Recognition*. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pages 770–778, 2016. (Cited on page 10.)

[Irvin 2019] Jeremy Irvin, Pranav Rajpurkar, Michael Ko, Yifan Yu, Silviana Ciosi, Cody Chute, Matthew P. Lungren and Andrew Y. Ng. *CheXpert: A Large Chest Radiograph Dataset with Uncertainty Labels and Expert Comparison*. In Proceedings of the AAAI Conference on Artificial Intelligence, volume 33, pages 590–597, 2019. (Cited on page 10.)

[Larrazabal 2020] Agostina J. Larrazabal, Nicolás Nieto, Victoria Peterson, Diego H. Milone and Enzo Ferrante. *Gender imbalance in medical imaging datasets produces biased classifiers for computer-aided diagnosis*. Proceedings of the National Academy of Sciences, vol. 117, no. 23, pages 12592–12594, 2020. (Cited on pages 2 and 5.)

[Seyyed-Kalantari 2021] Laleh Seyyed-Kalantari, Haoran Zhang, Matthew B. A. McDermott, Irene Y. Chen and Marzyeh Ghassemi. *CheXclusion: Fairness gaps in deep chest X-ray classifiers*. In Pacific Symposium on Biocomputing, volume 26, pages 232–243, 2021. (Cited on pages 2, 3 and 5.)

[Wang 2017] Xiaosong Wang, Yifan Peng, Le Lu, Zhiyong Lu, Mohammadhadi Bagheri and Ronald M. Summers. *ChestX-ray8: Hospital-scale Chest X-ray Database and Benchmarks on Weakly-Supervised Classification and Localization of Common Thorax Diseases*. In Proceedings of the IEEE

Conference on Computer Vision and Pattern Recognition (CVPR), pages 3462–3471, 2017. (Cited on page 9.)

[World Health Organization 2024] World Health Organization. *Pneumonia*. Available at https://www.who.int/health-topics/pneumonia, 2024. Accessed: June 2026. (Cited on page 9.)