Universitat de Girona
Escola Politècnica Superior

Treball Final de Màster

Estudi: Màster en Ciència de Dades

Títol: Equitat en Xarxes Neuronals Convolucionals per a la Predicció de Pneumònia: Anàlisi de la Codificació de Gènere en Representacions Intermèdies

Document: Memòria

Alumne: Joan Massallé Richart

Tutor: Jerónimo Hernández González
Departament: Informàtica, Matemàtica aplicada i Estadística
Àrea: Llenguatges i Sistemes Informàtics

Convocatòria: Juny 2026

Universitat de Girona
Escola Politècnica Superior

TREBALL FINAL DE MÀSTER

Equitat en Xarxes Neuronals Convolucionals per a la Predicció de Pneumònia: Anàlisi de la Codificació de Gènere en Representacions Intermèdies

Autor:
Joan MASSALLÉ

Juny 2026

Màster en Ciència de Dades

Tutors:
Jerónimo Hernández González

Resum

Malgrat el seu ús creixent en imatge mèdica, els models d'aprenentatge profund poden reproduir biaixos relacionats amb atributs com el gènere o l'ètnia, cosa que pot portar a resultats diagnòstics desiguals. Aquest treball examina com la informació sensible de gènere queda codificada en xarxes neuronals convolucionals (CNN) entrenades per detectar pneumònia en radiografies de tòrax, i si l'aplicació explícita d'una restricció de *fairness* té un impacte en aquesta codificació.

L'estudi empra principalment el dataset NIH ChestX-ray per a la predicció de pneumònia, i posteriorment s'ha estès l'anàlisi al dataset CheXpert. La pipeline implementada és genèrica i suporta qualsevol dataset de radiografies amb el format adequat. Després d'un preprocessament estàndard (filtrat, redimensionat, normalització i divisió train-test), les imatges s'utilitzen per entrenar un model. L'entrenament utilitza una funció de pèrdua que combina l'entropia creuada estàndard amb un terme de regularització de *fairness*, que penalitza les diferències en les taxes de vertaders positius (TPR) entre gèneres. Les representacions intermèdies de sis capes s'extreuen per analitzar com la informació de gènere queda codificada al llarg de la xarxa.

La hipòtesi central del treball és que, a l'hora de forçar el model a ser just, aquest necessita codificar activament el gènere del pacient en les seves representacions internes per tal d'igualar el seu comportament entre grups. És a dir, paradoxalment, l'aplicació de la restricció de *fairness* pot incrementar la presència d'informació de gènere a les capes de la xarxa, en lloc d'eliminar-la. Aquest treball té com a objectiu entendre i quantificar aquest fenomen, i analitzar com varia en funció de la capacitat del model i del pes de la penalització. El propòsit és millorar la comprensió del biaix en models neuronals per promoure sistemes de diagnosi més equitatius.

Índex

1 Introducció **1**
- 1.1 Context i motivació . . . 1
- 1.2 Problema i qüestions de recerca . . . 1
- 1.3 Contribucions . . . 2

2 Estat de l'art **5**
- 2.1 Justesa en aprenentatge automàtic . . . 5
- 2.2 Biaix en models de diagnosi mèdica . . . 5
- 2.3 Anàlisi de representacions internes . . . 6
- 2.4 Mètodes de regularització per a *fairness* . . . 7

3 Preliminars **9**
- 3.1 Domini: pneumònia i radiografia de tòrax . . . 9
- 3.2 Datasets emprats . . . 9
  - 3.2.1 NIH ChestX-ray . . . 9
  - 3.2.2 CheXpert . . . 10
  - 3.2.3 Altres datasets considerats . . . 10
- 3.3 Model: ResNet18 . . . 10
- 3.4 Nocions de *fairness* emprades . . . 11
  - 3.4.1 Taxa de vertaders positius (TPR) . . . 11
  - 3.4.2 Penalització de *fairness* basada en TPR . . . 11
  - 3.4.3 Decodificabilitat del gènere . . . 12

4 Planificació i Metodologia **13**
- 4.1 Metodologia general . . . 13
- 4.2 Pipeline d'entrenament . . . 13
- 4.3 Disseny del sweep experimental . . . 14

5 Contribució Metodològica **15**
- 5.1 Marc d'anàlisi de la codificació de gènere . . . 15
- 5.2 Regularització de *fairness* basada en diferència de TPR . . . 15
- 5.3 Interacció entre capacitat i *fairness* . . . 16

6 Resultats **17**
- 6.1 Rendiment diagnòstic i biaix de gènere . . . 17
  - 6.1.1 Rang baix d'α: la penalització és inerta . . . 17
  - 6.1.2 Rang alt d'α: trade-off fairness–diagnòstic . . . 18

6.2 Codificació del gènere a la capa intermèdia 19
6.3 Comparació entre NIH ChestX-ray i CheXpert 19

7 Conclusions i treball futur **21**
7.1 Conclusions 21
7.2 Treball futur 21

Bibliografia **23**

CAPÍTOL 1

Introducció

1.1 Context i motivació

L'aprenentatge profund ha experimentat un creixement extraordinari en el camp de la imatge mèdica durant l'última dècada. Els models basats en xarxes neuronals convolucionals (CNN) han assolit resultats comparables o fins i tot superiors als clínics en tasques com la detecció de càncer de pell, la identificació de retinopatia diabètica o el diagnòstic de malalties pulmonars a partir de radiografies de tòrax. Tanmateix, l'aplicació d'aquests models en entorns clínics reals planteja qüestions ètiques fonamentals que van més enllà de la precisió diagnòstica.

Un d'aquests reptes és el biaix algorísmic: la tendència dels models d'aprenentatge automàtic a reproduir, i de vegades amplificar, desigualtats presents a les dades d'entrenament. En l'àmbit mèdic, això pot traduir-se en diferències en la qualitat del diagnòstic en funció del gènere, l'ètnia o altres atributs sensibles del pacient. Un sistema que diagnostica la pneumònia amb alta precisió per als homes però amb pitjors resultats per a les dones no és només menys precís: és intrínsecament injust i potencialment perjudicial.

La hipòtesi de partida d'aquest treball és que **a l'hora de forçar el model a ser just, aquest necessita codificar activament el gènere del pacient en les seves representacions internes**. Per poder igualar el seu comportament entre grups, el model ha de "saber" a quin grup pertany cada pacient, i per tant el gènere emergeix a les capes de la xarxa com a conseqüència de la pròpia penalització. Paradoxalment, la restricció de *fairness* no elimina la codificació del gènere sinó que la pot incrementar respecte a un model no penalitzat.

1.2 Problema i qüestions de recerca

El biaix de gènere en models de diagnosi mèdica no és únicament un problema de rendiment: és un problema de *fairness*. Si el model presenta diferències significatives en la seva taxa de vertaders positius (TPR) entre homes i dones, pacients d'un gènere podran rebre diagnòstics incorrectes amb major freqüència que els de l'altre.

La solució intuïtiva és penalitzar el model per aquest biaix durant l'entrenament. Tanmateix, aquest treball parteix d'una observació contraintuïtiva: per poder reduir la diferència de TPR entre grups, el model ha de ser capaç de distingir-los internament. Forçar la *fairness* pot, per tant, induir el model a codificar el gènere de manera més explícita a les seves representacions intermèdies.

En aquest treball abordem les següents qüestions de recerca:

1. **Codificació del gènere:** La informació de gènere queda codificada en les representacions intermèdies d'una CNN entrenada per detectar pneumònia, malgrat no haver estat introduïda explícitament al model? Per respondre aquesta pregunta s'utilitza la tècnica de *linear probing*: s'entrena un classificador lineal (regressió logística) a partir de les activacions de cada capa per predir el gènere del pacient. Si l'AUC ROC d'aquest classificador supera significativament 0.5, es conclou que la informació de gènere és linealment accessible des d'aquella capa.

2. **Impacte de la capacitat de la xarxa:** La mida de la capa final de la xarxa influeix en la quantitat d'informació de gènere que el model és capaç de retenir?

3. **Efecte de la penalització de *fairness*:** L'addició del terme de regularització incrementa la presència d'informació de gènere a les capes internes de la xarxa, com a conseqüència del fet que el model necessita distingir els grups per igualar el seu comportament?

1.3 Contribucions

Les contribucions principals d'aquest treball són:

- **Metodologia d'anàlisi de representacions:** Es proposa un marc d'anàlisi basat en *linear probing* per mesurar quantitativament la informació de gènere present a sis punts de la xarxa: (1) després del bloc convolucional inicial (post-maxpool), (2–4) després de cada un dels tres primers blocs residuals (layer1, layer2, layer3), (5) després del quart bloc residual i el pooling global (avgpool), i (6) a la sortida de la capa intermèdia densa afegida, just abans de la classificació final.

- **Sweep experimental:** Es dissenya i s'executa un conjunt d'experiments sistemàtics que explora la interacció entre la mida de la capa final i el pes de la penalització de *fairness*, permetent analitzar de manera conjunta la capacitat del model i el grau de restricció de *fairness*.

- **Anàlisi del biaix de gènere:** Es quantifica el biaix de gènere en termes de diferència de TPR i es relaciona amb la presència de la informació de gènere a les representacions internes de la xarxa. L'ús de la diferència de TPR com a mètrica de biaix segueix la metodologia del paper *CheXclusion* [Seyyed-Kalantari 2021], que la valida en el context de les radiografies de tòrax.

Durant el desenvolupament del treball es van considerar diverses funcions de penalització de *fairness*: paritat demogràfica, *equalized odds* i regularització basada en independència estadística (HSIC). Finalment es va optar per la penalització basada en diferència de TPR, tant per la seva alineació amb la mètrica d'avaluació principal com pel seu precedent en la literatura de *fairness* en imatge mèdica.

CAPÍTOL 2

Estat de l'art

2.1 Justesa en aprenentatge automàtic

La *fairness* en aprenentatge automàtic és un camp de recerca en ràpid creixement que estudia com garantir que els models no discriminin individus o grups en funció d'atributs sensibles (*protected attributes*) com el gènere, l'ètnia o l'edat [Barocas 2023]. Existeixen múltiples definicions matemàtiques de *fairness*, cadascuna capturant un aspecte diferent de l'equitat:

- **Paritat demogràfica (*Demographic Parity*):** La probabilitat de predicció positiva és igual per a tots els grups, independentment de si la predicció és correcta.
- **Igualtat d'oportunitats (*Equalized Odds*):** Les taxes de vertaders positius (TPR) i falsos positius (FPR) són iguals per a tots els grups.
- **Igualtat de la taxa de vertaders positius (*Equal TPR*):** Cas particular dels Equalized Odds que només considera la TPR, garantint que el model detecta la condició positiva amb la mateixa freqüència per a tots els grups.

La paritat demogràfica i les nocions d'igualtat d'oportunitats es discuteixen en detall a [Barocas 2023]. La definició formal d'*equalized odds* i la seva relaxació (*equal opportunity*) es deuen a Hardt et al. [Hardt 2016].

2.2 Biaix en models de diagnosi mèdica

El biaix en intel·ligència artificial aplicada a la medicina ha estat documentat en diversos dominis. Estudis han demostrat que models de diagnosi d'imatge mèdica poden presentar diferències significatives de rendiment en funció del gènere o l'ètnia, derivades principalment de desbalancejos al dataset d'entrenament o de correlacions espúries entre els atributs sensibles i les característiques rellevants per al diagnòstic [Larrazabal 2020].

En el cas concret de les radiografies de tòrax, el paper *CheXclusion* [Seyyed-Kalantari 2021] demostra l'existència de diferències sistemàtiques en la taxa de vertaders positius (TPR) de classificadors profunds en funció del gènere i l'ètnia,

analitzant diversos datasets incloent el NIH ChestX-ray. Aquest treball utilitza la diferència de TPR entre grups com a mètrica de biaix, la mateixa que s'adopta en la present memòria.

Factors anatòmics com la mida dels pulmons, la densitat del teixit gras i muscular o la presentació clínica de la pneumònia poden diferir entre homes i dones. Això implica que un model que aprengui a usar aquestes diferències per al diagnòstic podria estar indirectament codificant informació de gènere, fins i tot quan aquesta variable no és explícitament proporcionada com a entrada.

2.3 Anàlisi de representacions internes

Per estudiar quina informació queda codificada a les capes intermèdies d'una xarxa neuronal s'han proposat diverses tècniques:

- ***Linear probing*:** S'entrena un classificador lineal (típicament una regressió logística) a partir de les activacions d'una capa per predir una propietat d'interès. Si el classificador obté una alta precisió, es conclou que la informació és linealment accessible des d'aquella capa. És la tècnica adoptada en el present treball.

Existeixen altres tècniques per analitzar representacions que no s'han implementat en el marc actual però que constitueixen línies de treball futur:

- **MMD (*Maximum Mean Discrepancy*):** Mesura la distància entre les distribucions de les representacions de dos grups sense necessitat d'entrenar cap model.

- **HSIC (*Hilbert-Schmidt Independence Criterion*):** Mesura la dependència estadística entre representacions i atributs en un espai de kernels, i pot ser usat tant com a mètrica d'anàlisi com directament com a terme de *loss* de disentanglement.

- **CKA (*Centered Kernel Alignment*):** Mesura la similitud entre representacions de dues xarxes o dues capes, invariant a transformacions ortogonals i d'escalat.

- **Grad-CAM:** Genera mapes de rellevància que mostren quines zones de la imatge d'entrada han estat més determinants per a la predicció del model. Útil per a interpretabilitat però no per a la quantificació de codificació d'atributs.

2.4 Mètodes de regularització per a *fairness*

Els mètodes de regularització per a *fairness* s'emmarca dins del que s'anomena *in-processing*: intervencions aplicades directament durant l'entrenament del model, en contrast amb els mètodes de *pre-processing* (que modifiquen les dades) i els de *post-processing* (que ajusten les prediccions a posteriori) [Barocas 2023].

Els enfocaments d'*in-processing* més habituals inclouen:

- **Regularització per penalització directa:** S'afegeix un terme a la funció de pèrdua que penalitza el biaix mesurat en cada *batch*. La penalització pot basar-se en diferència de TPR, diferència de probabilitats de predicció (*demographic parity loss*) o altres mètriques de disparitat. És l'estratègia adoptada en el present treball.

- **Regularització adversarial:** S'entrena conjuntament el model principal i un discriminador que intenta predir l'atribut sensible (en el nostre cas, el gènere) a partir de les representacions intermèdies. L'objectiu és maximitzar el rendiment diagnòstic mentre es minimitza la capacitat del discriminador, induint representacions que no continguin informació de gènere.

- **Restriccions de *fairness*:** Formulació del problema d'entrenament com una optimització amb restriccions explícites sobre les mètriques de fairness, resoltes típicament amb mètodes de multiplicadors de Lagrange.

En el present treball s'utilitza la regularització per penalització directa basada en la diferència de probabilitats de predicció positiva entre gèneres (Equació 3.2), donat que permet un control senzill i gradual del pes de la restricció mitjançant el paràmetre α.

CAPÍTOL 3

Preliminars

3.1 Domini: pneumònia i radiografia de tòrax

La pneumònia és una infecció del parènquima pulmonar que provoca la inflamació dels alvèols, que s'omplen de fluid o de pus. És una de les principals causes de mortalitat a nivell mundial, especialment en nens i persones grans. El diagnòstic clínic es basa en l'examen físic, l'anàlisi de símptomes i, sovint, la radiografia de tòrax (RX de tòrax).

En una RX de tòrax, la pneumònia es manifesta típicament com una opacificació o consolidació del teixit pulmonar en una zona concreta. La interpretació d'aquest tipus d'imatge requereix experiència clínica, i la detecció automatitzada mitjançant CNN ha estat objecte de recerca intensa en els darrers anys.

3.2 Datasets emprats

La pipeline implementada en aquest treball és genèrica: accepta qualsevol dataset que proporcioni una taula de metadades de pacients (amb columnes d'imatge, etiqueta de classe i gènere) i una carpeta d'imatges corresponent. S'han emprat principalment dos datasets:

3.2.1 NIH ChestX-ray

El dataset NIH ChestX-ray [Wang 2017] és un conjunt de dades públic alliberat pel National Institutes of Health (NIH) dels Estats Units. Conté més de 100.000 radiografies de tòrax etiquetades amb catorze patologies pulmonars, extretes de l'arxiu clínic del NIH Clinical Center. Cada imatge inclou metadades com el gènere i l'edat del pacient. És el dataset principal d'aquest treball, usat en tots els experiments inicials.

Per a aquest treball s'han seleccionat únicament les imatges etiquetades com a *Pneumonia* o *No Finding*, reduint el problema a una classificació binària. El dataset presenta un desbalanceig natural tant per classe (la classe positiva és minoritària) com per subgrup (class × gènere), circumstància que s'ha de tenir en compte tant en l'entrenament com en l'avaluació.

Les imatges es preprocessen de la manera següent:

1. Filtrat per retenir únicament les classes d'interès (*Pneumonia* i *No Finding*).
2. Redimensionat a 224 × 224 píxels (mida estàndard per a models pre-entrenats amb ImageNet).
3. Conversió a format RGB de tres canals (tot i que les radiografies originals són en escala de grisos, el model pre-entrenat requereix imatges en color).
4. Normalització amb les estadístiques estàndard d'ImageNet (mitjana i desviació típica per canal).
5. Divisió en conjunts de train, validació i test, estratificada per classe.

3.2.2 CheXpert

CheXpert és un dataset públic de radiografies de tòrax alliberat per Stanford University. Conté més de 200.000 imatges amb etiquetes per a catorze patologies, incloent metadades de gènere. S'ha incorporat als experiments posteriorment al NIH ChestX-ray, aplicant el mateix pipeline de preprocessament i la mateixa metodologia d'anàlisi.

3.2.3 Altres datasets considerats

Durant el desenvolupament del treball es va considerar també l'ús del dataset MIMIC-CXR (PhysioNet), que és una altra font important de radiografies de tòrax amb metadades de gènere i ètnia. No ha estat possible accedir-hi perquè l'obtenció de les credencials d'accés requereix la superació del curs d'ètica de la recerca del CITI Program (*Collaborative Institutional Training Initiative*), un curs de pagament per al qual la Universitat de Girona no disposa d'un acord institucional en el moment de realitzar aquest treball. L'ús de MIMIC-CXR queda com a línia de treball futur.

3.3 Model: ResNet18

La ResNet18 (*Residual Network* de 18 capes) és una arquitectura CNN proposada per He et al. [He 2016] que va revolucionar el camp de la visió per computador gràcies a l'ús de connexions residuals (*skip connections*), que permeten entrenar xarxes molt profundes sense patir el problema del gradient evanescent (*vanishing gradient*).

En aquest treball s'utilitza una ResNet18 pre-entrenada amb el dataset ImageNet. Les últimes capes de classificació (fully connected) es substitueixen per

una nova capa densa configurable de mida *last_layer_size*, seguida d'una capa de sortida de dues neurones (pneumònia / no pneumònia). Els pesos de la ResNet18 pre-entrenada es mantenen congelats durant l'entrenament: només s'actualitzen els paràmetres de la capa densa intermèdia i la capa de classificació afegides. Aquesta estratègia aprofita les representacions visuals apreses en ImageNet i centra l'aprenentatge en les noves capes.

L'entrenament combina dues components de pèrdua: la pèrdua d'entropia creuada ($\mathscr{L}_{CE}$), que garanteix el rendiment diagnòstic, i la pèrdua de *fairness* ($\mathscr{L}_{fair}$), que penalitza les diferències de predicció entre gèneres. El paràmetre $\alpha \geq 0$ controla el pes relatiu de la penalització: $\alpha = 0$ produeix un model estàndard sense cap restricció de *fairness*, mentre que valors creixents d'α incrementen progressivament el cost del biaix. La pèrdua total és $\mathscr{L}_{total} = \mathscr{L}_{CE} + \alpha \cdot \mathscr{L}_{fair}$ (Equació 3.3).

3.4 Nocions de *fairness* emprades

3.4.1 Taxa de vertaders positius (TPR)

La taxa de vertaders positius (TPR), també anomenada *recall* o sensibilitat, es defineix per a un grup g com:

$$\mathrm{TPR}_g = \frac{\mathrm{TP}_g}{\mathrm{TP}_g + \mathrm{FN}_g} \tag{3.1}$$

on TP_g és el nombre de vertaders positius i FN_g el nombre de falsos negatius per al grup g.

3.4.2 Penalització de *fairness* basada en TPR

La penalització de *fairness* emprada en aquest treball es basa en minimitzar la diferència en la probabilitat de predicció positiva entre els dos grups de gènere. Formalment, per a un batch d'entrenament, la fairness loss es defineix com:

$$\mathscr{L}_{fair} = (\bar{p}_{homes} - \bar{p}_{dones})^2 \tag{3.2}$$

on $\bar{p}_{homes}$ i $\bar{p}_{dones}$ són les probabilitats de predicció positiva mitjanes per al grup d'homes i de dones respectivament dins del batch.

La funció de pèrdua total és:

$$\mathscr{L}_{total} = \mathscr{L}_{CE} + \alpha \cdot \mathscr{L}_{fair} \tag{3.3}$$

on $\alpha \geq 0$ és un hiperparàmetre que controla el pes relatiu de la penalització.

Quan $\alpha = 0$ el model s'entrena sense restricció de *fairness*; a mesura que α augmenta, el model és penalitzat amb major intensitat per les diferències de predicció entre gèneres.

3.4.3 Decodificabilitat del gènere

Per mesurar quantitativament la presència d'informació de gènere a una capa de la xarxa, s'utilitza la tècnica de *linear probing*: s'entrena una regressió logística per predir el gènere del pacient a partir de les activacions de la capa. La mètrica principal és l'AUC ROC del classificador de gènere, on un valor proper a 0.5 indica que el gènere no és linealment decodificable des d'aquella capa, mentre que un valor proper a 1.0 indica que el gènere hi és fortament codificat. Cal tenir en compte que el *linear probing* únicament detecta codificació *lineal*: si la informació de gènere estigués present però representada de manera no lineal, l'AUC del classificador logístic podria ser propera a 0.5 malgrat que el gènere hi fos codificat.

CAPÍTOL 4

Planificació i Metodologia

4.1 Metodologia general

El projecte segueix una metodologia iterativa pròpia de la ciència de dades. El punt de partida és un script experimental proporcionat pel tutor, que implementa el pipeline bàsic d'entrenament amb penalització de *fairness* i l'extracció de representacions intermèdies. A partir d'aquest codi base, s'han realitzat les passes següents:

1. **Comprensió i refactorització del codi base:** Anàlisi detallada de l'script original, estudi de l'arquitectura ResNet18 modificada i dels mecanismes de càlcul del gradient.

2. **Exploració inicial:** Entrenaments amb hiperparàmetres estàndard per verificar el comportament del model (sobreajust, convergència, etc.).

3. **Disseny del sweep experimental:** Definició de la graella d'experiments (combinacions de *last_layer_size* $\times$ α) per explorar de manera sistemàtica l'espai de configuracions.

4. **Execució del sweep:** Entrenament de tots els models de la graella i emmagatzematge dels resultats.[1]

5. **Anàlisi de representacions:** Extracció de les representacions intermèdies de cada model entrenat i aplicació del *linear probing* per a cada capa.

6. **Anàlisi de resultats:** Visualització i interpretació dels resultats en termes de biaix de gènere i decodificabilitat.

4.2 Pipeline d'entrenament

El pipeline d'entrenament implementat en PyTorch consta dels elements principals següents:

[1] Els experiments del sweep s'han executat fent ús dels recursos computacionals (GPU) posats a disposició per la Universitat de Girona.

- **Dataset:** `ChestXrayDataset`, una classe que retorna tres dades (imatge, etiqueta de classe i etiqueta de gènere) per a cada mostra.
- **Model:** ResNet18 pre-entrenada amb les últimes capes substituïdes per una capa densa de mida *last_layer_size* i una capa de sortida de dos neurones.
- **Funció de pèrdua:** Combinació d'entropia creuada i fairness loss tal com es descriu a l'Equació 3.3.
- **Reproductibilitat:** Fixació de totes les llavors aleatòries (Python, NumPy, PyTorch, CUDA) per garantir la reproductibilitat dels experiments.

4.3 Disseny del sweep experimental

El sweep experimental explora la interacció entre dos hiperparàmetres principals:

- ***last_layer_size* (ls):** Mida de la capa densa intermèdia (la penúltima capa de la xarxa). Valors explorats: {8, 16, 32, 64, 256}. Controla la capacitat del coll d'ampolla de la xarxa, i per tant la quantitat d'informació que pot fluir fins a la capa de classificació. La seva influència sobre la codificació del gènere s'analitza en detall als resultats.
- **α:** Pes de la penalització de *fairness*. Valors explorats: {1, 2.5, 5, 7.5, 10, 25, 50, 75, 100, 250, 500, 750, 1000} (13 valors). A mesura que α augmenta, el cost d'exhibir biaix de gènere durant l'entrenament creix. El rang és deliberadament ampli per poder observar el comportament del model en condicions de penalització extrema.

Per a cada combinació (ls, α), s'entrenen 20 models amb llavors aleatòries diferents i se n'agreguen els resultats (mitjana i desviació típica). Aquesta repetició proporciona estimacions robustes de: la pèrdua d'entrenament i validació, l'AUC diagnòstica, la diferència de TPR entre gèneres, i l'AUC del classificador de gènere per a cadascun dels sis punts d'extracció analitzats.

CAPÍTOL 5

Contribució Metodològica

5.1 Marc d'anàlisi de la codificació de gènere

La contribució metodològica central d'aquest treball és un marc d'anàlisi per estudiar com la informació de gènere queda distribuïda al llarg de les capes d'una CNN, i com aquesta distribució canvia en funció dels hiperparàmetres d'entrenament.

El marc consisteix en tres components:

1. **Extracció de representacions:** S'extreuen les activacions en sis punts de la xarxa (post-maxpool, post-layer1, post-layer2, post-layer3, post-avgpool i capa intermèdia) per a totes les mostres del conjunt de test.

2. ***Linear probing*:** Per a cada capa i cada model entrenat, s'entrena una regressió logística per predir el gènere del pacient a partir de les activacions. Es fa servir validació creuada i es reporta l'AUC ROC.

3. **Anàlisi combinada:** Es visualitza l'AUC del classificador de gènere en funció de la capa, el *last_layer_size* i el valor d'α, permetent detectar patrons en com la penalització de *fairness* altera la codificació del gènere a la xarxa.

5.2 Regularització de *fairness* basada en diferència de TPR

La regularització de *fairness* implementada actua directament sobre el procés d'optimització: en cada pas d'entrenament, el gradient total incorpora un terme que penalitza la diferència de probabilitats de predicció entre gèneres. Això s'implementa calculant dos gradients separats: un primer gradient per a la loss d'entropia creuada (que garanteix el rendiment diagnòstic) i un segon gradient per a la loss total (que incorpora la penalització de *fairness*).

Aquesta estratègia permet un control explícit i gradual del biaix de gènere mitjançant el paràmetre α: establir $\alpha = 0$ produeix un model estàndard sense restriccions, mentre que augmentar α incrementa progressivament el cost del biaix.

5.3 Interacció entre capacitat i *fairness*

Una de les preguntes centrals del treball és si el model *necessita* codificar el gènere per funcionar bé, o si simplement ho fa perquè té la capacitat de fer-ho. El disseny experimental explora aquesta interacció limitant la capacitat del model a través del paràmetre *last_layer_size*: una capa molt petita (per exemple, ls = 8) restringeix físicament la quantitat d'informació que pot ser retinguda fins al final de la xarxa, cosa que permet aïllar si el gènere és estrictament necessari per al diagnòstic o simplement accessible.

CAPÍTOL 6

Resultats

Els resultats presentats en aquest capítol provenen de quatre experiments de sweep sistemàtic (Taula 6.1). Els dos primers cobreixen un rang baix de penalització ($\alpha \in [0{,}2, 1{,}2]$) sobre el NIH ChestX-ray i el CheXpert; els dos darrers exploren un rang molt més ampli ($\alpha \in [1, 1000]$) per determinar si existeix algun llindar a partir del qual la penalització es torna efectiva. Per a cada combinació (ls, α), s'han entrenat 20 models amb llavors aleatòries independents, cosa que proporciona estimacions robustes de totes les mètriques reportades.

Exp.	**Dataset**	**Rang α**	**Valors *ls***	**Runs**
E1	NIH ChestX-ray	[0,2, 1,2]	4–48	1080
E2	CheXpert	[0,2, 1,2]	4–48	1080
E3	NIH ChestX-ray	[1, 1000]	2–8	1040
E4	CheXpert	[1, 1000]	2–8	1040

Taula 6.1: Resum dels quatre experiments analitzats. Per a cada combinació (ls, α), s'han entrenat 20 models amb llavors aleatòries independents.

6.1 Rendiment diagnòstic i biaix de gènere

6.1.1 Rang baix d'α: la penalització és inerta

Les Figures 6.1–6.4 segueixen la mateixa estructura de tres panells: **esquerra**, AUC del classificador de gènere a l'última capa vs. Gap TPR (±desv. est.); **centre**, mateixa relació amb línies que connecten els valors de *ls* per a un α fix; **dreta**, AUC diagnòstica vs. Gap TPR.

En el rang $\alpha \in [0{,}2, 1{,}2]$, la penalització de *fairness* no produeix cap efecte mesurable. La Figura 6.1 (panell dret) mostra que tots els punts s'acumulen en una banda quasi vertical (AUC $\in [0{,}858, 0{,}862]$): les sis condicions d'α se superposen completament i el Gap TPR oscil·la entre 0,035 i 0,050 sense correlació amb α.

El panell esquerre de la mateixa figura mostra que l'AUC de gènere varia entre 0,50 i 0,90, però impulsada quasi exclusivament per *ls*: els punts es diferencien per símbol (un per valor de *ls*), mentre que punts del mateix *ls* amb α

diferent estan completament solapats. En aquest règim, α no mou ni el biaix ni la codificació del gènere.

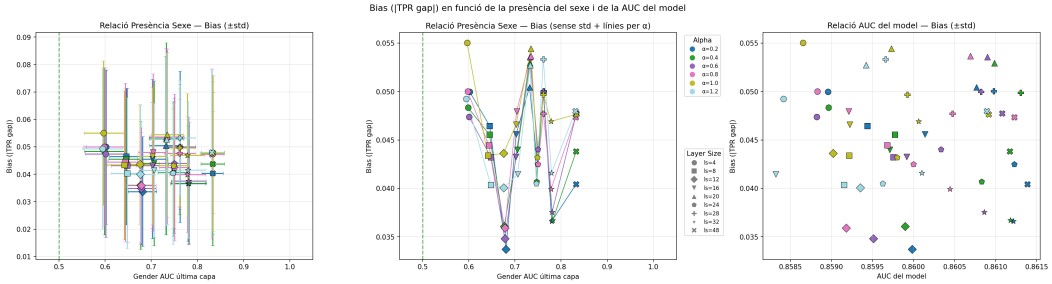


Figura 6.1: Experiment E1: NIH ChestX-ray, $\alpha \in [0{,}2, 1{,}2]$. Les condicions d'$\alpha$ se superposen en tots els panells: la penalització és inerta en aquest rang.

6.1.2 Rang alt d'α: trade-off fairness–diagnòstic

En el rang $\alpha \in [1, 1000]$ apareix un *trade-off* clar. La Figura 6.2 (panell dret) mostra com, a mesura que α augmenta, l'AUC diagnòstica disminueix i el Gap TPR s'aproxima a zero. Per a $\alpha = 1$, el model assoleix una AUC de 0,857 amb un Gap TPR de 0,050; per a $\alpha = 50$, l'AUC cau a 0,682 i el gap es redueix a 0,010; per a $\alpha = 1000$, l'AUC és de 0,525 i el gap és de 0,007.

La reducció del biaix no és lineal: la caiguda més pronunciada del Gap TPR ocorre entre $\alpha = 10$ i $\alpha = 50$, que és precisament la zona on l'AUC diagnòstica comença a degradar-se de forma accelerada (de 0,833 a 0,682). Per sobre de $\alpha = 50$, la millora en equitat és mínima (el gap passa de 0,010 a 0,007) mentre l'AUC continua deteriorant-se fins a nivells propers al classificador aleatori. Això evidencia l'existència d'un llindar crític al voltant de $\alpha \approx 25$–50 a partir del qual la penalització es torna efectiva, però a un cost diagnòstic sever.

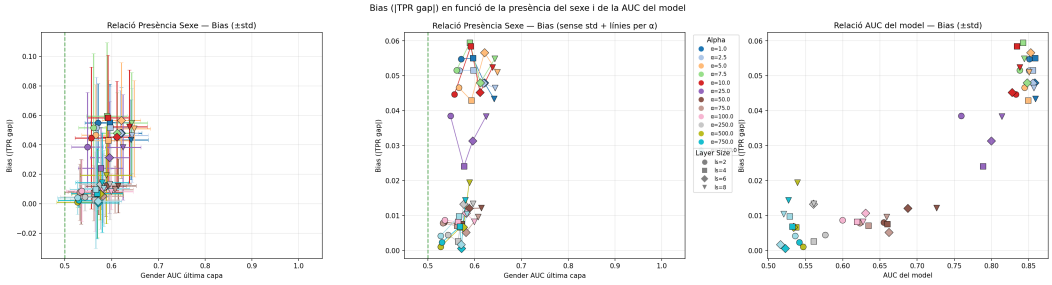


Figura 6.2: Experiment E3: NIH ChestX-ray, $\alpha \in [1, 1000]$. El panell dret evidencia el *trade-off*: α creixent desplaça els punts de dalt-dreta (alta AUC, alt biaix) cap a baix-esquerra (baixa AUC, baix biaix).

6.2 Codificació del gènere a la capa intermèdia

El panell esquerre de les Figures 6.1 i 6.2 mostra la relació entre l'AUC del classificador de gènere a l'última capa i el Gap TPR. Dos patrons ressalten en l'anàlisi conjunta dels quatre experiments:

Persistència de la informació de gènere. En cap experiment el classificador de gènere cau per sota de 0,50 de forma consistent. A $\alpha = 1000$ (la penalització màxima testada), l'AUC de gènere a la capa intermèdia es manté entre 0,55 i 0,62 al NIH. La informació de gènere no desapareix de les representacions intermèdies. Una possible explicació és que els pesos del backbone ResNet18 estan congelats: l'extracció de característiques de les capes convolucionals ja inclou informació de gènere que flueix cap a la capa intermèdia sense que la penalització de *fairness* hi pugui actuar.

Efecte de la mida de capa. En tots els experiments, *ls* és el principal determinant de l'AUC de gènere a l'última capa. Augmentar *ls* incrementa de forma monòtona la decodificabilitat: de $\approx 0{,}60$ per a $ls = 4$ fins a $\approx 0{,}83$ per a $ls = 48$ al NIH (experiment E1). Una capa més ampla té més capacitat per retenir la informació de gènere procedent del backbone, però, un cop s'aplica la penalització amb α alt, aquesta capacitat addicional no es tradueix en biaix addicional: en el panell central de la Figura 6.2, les línies de α elevat convergeixen en valors de gap baixos independentment de *ls*.

6.3 Comparació entre NIH ChestX-ray i CheXpert

Les Figures 6.3 i 6.4 mostren els resultats equivalents per al dataset CheXpert.

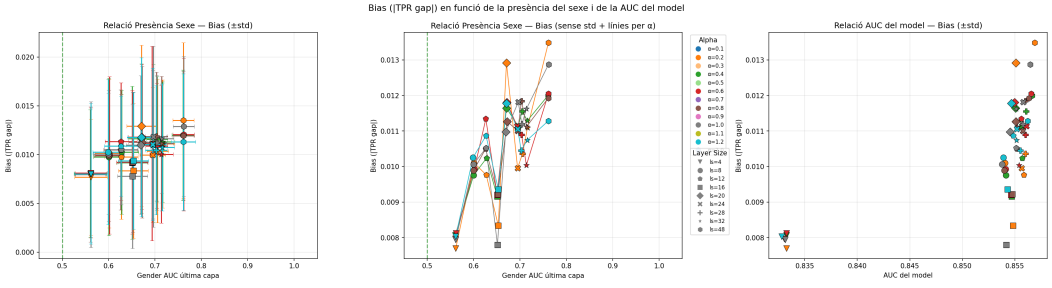


Figura 6.3: Experiment E2 (CheXpert, $\alpha \in [0{,}2, 1{,}2]$, 20 runs/config). El panell dret mostra totes les configuracions concentrades en una banda quasi vertical (AUC $\in [0{,}835, 0{,}855]$) amb un biaix de partida molt baix ($\approx 0{,}010$). Com a l'experiment E1, α és completament inert en aquest rang.

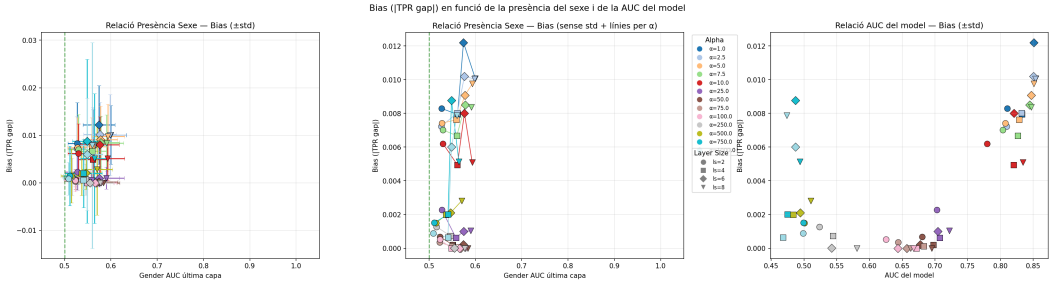


Figura 6.4: Experiment E4 (CheXpert, $\alpha \in [1, 1000]$, 20 runs/config). El panell dret mostra el mateix *trade-off* monòton que per al NIH, però amb un biaix de partida quatre vegades inferior. L'AUC de gènere (panell esquerre) és sistemàticament més baixa que per al NIH, situant-se entre 0,49 i 0,66.

La comparació entre els dos datasets revela diferències quantitatives importants que mantenen el mateix patró qualitatiu:

- **Biaix de partida.** CheXpert presenta un Gap TPR inicial (a $\alpha = 1$) de 0,010, aproximadament quatre vegades inferior al del NIH (0,050). Això suggereix que la composició demogràfica i la naturalesa de les etiquetes de CheXpert generen menys biaix de gènere intrínsec.

- **Llindar crític d'α.** Al CheXpert, la reducció significativa del biaix s'inicia a $\alpha \approx 10$–25 (el gap passa de 0,006 a 0,001), mentre que al NIH el llindar és $\alpha \approx 25$–50. L'equitat de facto s'assoleix amb penalitzacions menors al CheXpert, probablement perquè el biaix a corregir és menys profundament arrelat en la distribució de les dades.

- **Codificació del gènere.** L'AUC de gènere a l'última capa és sistemàticament 0,05–0,07 unitats inferior al CheXpert que al NIH en condicions comparables ($\approx$ 0,57 vs $\approx$ 0,61 a $\alpha = 1$ en el rang alt). La informació de gènere és menys linealment accessible en les representacions que el backbone extreu d'aquest dataset, però persisteix per sobre de 0,50 en tots els casos.

- **Cost en rendiment diagnòstic.** La degradació de l'AUC diagnòstica segueix una corba similar en ambdós datasets. Per a $\alpha = 10$, l'AUC és 0,833 al NIH i 0,814 al CheXpert; per a $\alpha = 50$, és 0,682 i 0,688 respectivament. El cost de la penalització sobre la qualitat del diagnòstic és comparable entre els dos conjunts de dades.

CAPÍTOL 7

Conclusions i treball futur

7.1 Conclusions

7.2 Treball futur

Les línies de treball futur identificades durant el desenvolupament del projecte inclouen:

- **Estratificació per (class × gènere):** L'split actual únicament estratifica per classe. Estratificar per (classe × gènere) garantiria una distribució equitativa de subgrups entre train, validació i test.
- **Gestió del desbalanceig de subgrups:** L'ús de `WeightedRandomSampler` per equilibrar els subgrups (classe × gènere) en l'entrenament podria millorar la qualitat de la penalització de *fairness*.
- **Mètodes alternatius d'anàlisi de representacions:** Explorar MMD, HSIC, CKA o informació mútua com a alternatives o complements al *linear probing* (el qual únicament detecta codificació lineal).
- **Fine-tuning complet:** El marc actual congela els pesos de la ResNet18 i entrena únicament les capes afegides. Explorar el fine-tuning parcial o complet permetria analitzar com l'adaptació de les capes convolucionals influeix en la codificació del gènere.
- **Accés al dataset MIMIC-CXR:** L'ús del dataset MIMIC-CXR (PhysioNet) permetria ampliar l'anàlisi a una cohort amb major diversitat demogràfica. L'accés requereix la certificació CITI, que queda pendent.
- **Data augmentation:** Aplicar augmentació de dades de manera que preservi l'equilibri entre subgrups (classe × gènere) per millorar la robustesa de l'entrenament.

Bibliografia

[Barocas 2023] Solon Barocas, Moritz Hardt and Arvind Narayanan. Fairness and Machine Learning: Limitations and Opportunities. MIT Press, 2023. (Cited on pages 5 and 7.)

[Hardt 2016] Moritz Hardt, Eric Price and Nati Srebro. *Equality of Opportunity in Supervised Learning*. In Advances in Neural Information Processing Systems (NeurIPS), volume 29, pages 3323–3331, 2016. (Cited on page 5.)

[He 2016] Kaiming He, Xiangyu Zhang, Shaoqing Ren and Jian Sun. *Deep Residual Learning for Image Recognition*. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pages 770–778, 2016. (Cited on page 10.)

[Larrazabal 2020] Agostina J. Larrazabal, Nicolás Nieto, Victoria Peterson, Diego H. Milone and Enzo Ferrante. *Gender imbalance in medical imaging datasets produces biased classifiers for computer-aided diagnosis*. Proceedings of the National Academy of Sciences, vol. 117, no. 23, pages 12592–12594, 2020. (Cited on page 5.)

[Seyyed-Kalantari 2021] Laleh Seyyed-Kalantari, Haoran Zhang, Matthew B. A. McDermott, Irene Y. Chen and Marzyeh Ghassemi. *CheXclusion: Fairness gaps in deep chest X-ray classifiers*. In Pacific Symposium on Biocomputing, volume 26, pages 232–243, 2021. (Cited on pages 3 and 5.)

[Wang 2017] Xiaosong Wang, Yifan Peng, Le Lu, Zhiyong Lu, Mohammadhadi Bagheri and Ronald M. Summers. *ChestX-ray8: Hospital-scale Chest X-ray Database and Benchmarks on Weakly-Supervised Classification and Localization of Common Thorax Diseases*. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pages 3462–3471, 2017. (Cited on page 9.)