# Anàlisi de la codificació del gènere en representacions intermèdies d'una CNN per estudi d'equitat en predicció de Pneumònia

Joan Massallé Richart

Màster en Ciència de Dades
Escola Politècnica Superior, Universitat de Girona
Tutor: Jerónimo Hernández González

Juny 2026

# Índex

1. Introducció i Objectius
2. Desenvolupament del Projecte
3. Conclusions

# Motivació

**Deep learning en diagnosi mèdica**

- Rendiment comparable al d'un radiòleg expert en detecció de pneumònia
- Models entrenats sobre grans conjunts de radiografies de tòrax

**Però...**

- Els models aprenen i ampliquen biaixos presents en les dades
- En context clínic: diagnòstic diferent per gènere, ètnia o edat
- Estudis mostren diferències sistemàtiques en sensibilitat (TPR) entre grups

## Pregunta clau

Com podem garantir que un model de diagnosi sigui *equitatiu* entre grups demogràfics?

## Estratègia habitual

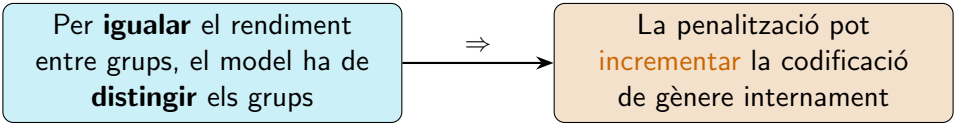
Afegir una **penalització d'equitat** a la funció de pèrdua per igualar el rendiment entre grups.

# Problema i Hipòtesi Central

## Mètode in-processing

Incorporar la restricció d'equitat *durant* l'entrenament: igualant la sensibilitat (TPR) entre homes i dones.

**Hipòtesi paradoxal:**




## Paradoxa de privacitat

Models dissenyats per ser equitatius poden codificar el gènere en les representacions latents.

# Preguntes de Recerca

**RQ1** Es codifica informació de gènere en les representacions intermèdies d'una CNN entrenada per detectar pneumònia, malgrat que el gènere no sigui una entrada explícita?

**RQ2** Influeix la mida de la capa densa final (*ls*) en quanta informació de gènere reté el model en les seves representacions?

**RQ3** Afegir una penalització d'equitat incrementa la codificació de gènere en les representacions internes del model?

# Objectius

- **Quantificar** la codificació de gènere capa a capa en una CNN sota entrenament amb restriccions d'equitat
- **Caracteritzar** el trade-off equitat–precisió diagnòstica en funció del pes de la penalització ($\alpha$)
- **Analitzar** l'efecte de la capacitat de la capa densa (*ls*) sobre la codificació de gènere
- **Comparar** els resultats en dos conjunts de dades amb biaixos intrínsecs de gènere coneguts

# Conjunts de Dades

## NIH ChestX-ray

- >100.000 radiografies de tòrax
- Biaix de gènere documentat a la literatura
- Permet estudiar l'efecte dels mètodes sobre un biaix real i conegut

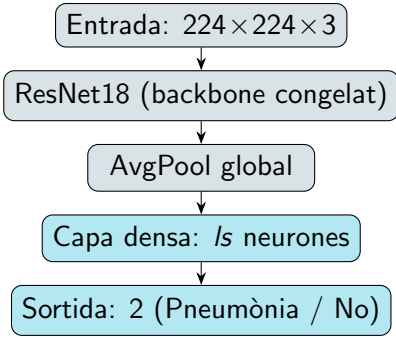
## CheXpert (Stanford)

- >200.000 radiografies de tòrax
- Biaix de gènere documentat, de menor intensitat que el NIH
- Permet contrastar la robustesa dels resultats

**Preprocessat comú:**

- Redimensionat a $224 \times 224$ px, conversió a RGB, normalització ImageNet
- Classificació binària: Pneumònia vs. No Pneumònia
- Divisió estratificada per classe i gènere (train / test)

# Arquitectura del Model




**Dos paràmetres experimentals:**

- $\alpha$: força de la penalització d'equitat
- *ls*: capacitat de la capa densa intermèdia

**Per què congelar el backbone?**

Permet aïllar l'efecte de la penalització i del paràmetre *ls* sobre la codificació de gènere.

# Funció de Pèrdua amb Equitat

## Pèrdua total

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{CE}} + \alpha \cdot \mathcal{L}_{\text{fair}}$$

**Mètrica de biaix — Gap TPR:**

$$\text{GapTPR} = \text{TPR}_{\text{homes}} - \text{TPR}_{\text{dones}}$$

**Pèrdua d'equitat (in-processing):**

$$\mathcal{L}_{\text{fair}} = \left(\bar{p}_{\text{homes}} - \bar{p}_{\text{dones}}\right)^2$$

calculat sobre les mostres positives del batch.

**Règims de $\alpha$:**

- $\alpha = 0$: cap restricció d'equitat
- $\alpha$ baix $[0.2, 1.2]$: penalització suau
- $\alpha$ alt $[1, 1000]$: penalització forta

## Objectiu

Reduir $\text{GapTPR} \to 0$ sense sacrificar l'AUC diagnòstica.

# Mètode d'Anàlisi: Linear Probing

**Idea:** si el model "sap" el gènere, un classificador lineal entrenat sobre les seves activacions ho detectarà.

**6 punts d'extracció de l'arquitectura:**

1. Post-maxpool
2. Post-layer1
3. Post-layer2
4. Post-layer3
5. Post-avgpool
6. **Capa densa (*ls*)** ← focus principal

Per cada punt: entrenar una **regressió logística** per predir el gènere.

**Mètrica: AUC ROC (gènere)**

- $\mathrm{AUC} = 0.5 \Rightarrow$ cap informació de gènere
- $\mathrm{AUC} = 1.0 \Rightarrow$ codificació perfecta

Interpretem l'AUC com a mesura de la **decodificabilitat lineal** del gènere en cada capa.

# Disseny Experimental

| Exp. | Dataset | Règim $\alpha$ | Valors *ls* | Models |
|---|---|---|---|---|
| E1 | NIH ChestX-ray | [0.2, 1.2] (baix) | $\{4, 8, \ldots, 48\}$ | 1.080 |
| E2 | CheXpert | [0.2, 1.2] (baix) | $\{4, 8, \ldots, 48\}$ | 1.080 |
| E3 | NIH ChestX-ray | [1, 1000] (alt) | $\{2, 4, 8\}$ | 1.040 |
| E4 | CheXpert | [1, 1000] (alt) | $\{2, 4, 8\}$ | 1.040 |
| | | | **Total:** | **4.240** |

- Cada configuració entrenada **20 vegades** amb llavors aleatòries independents
- E1/E2: detectar si penalitzacions suaus ja tenen efecte mesurable
- E3/E4: identificar el llindar crític on la penalització s'activa

# Resultat 1: Penalització Inerta a $\alpha$ Baix

**En experiments E1 i E2 ($\alpha \in [0.2, 1.2]$):**

- El Gap TPR **no varia** significativament amb $\alpha$
- L'AUC de gènere a la capa densa **no canvia** amb $\alpha$
- Tota la variabilitat observada s'explica per *ls*, no per $\alpha$

## Interpretació

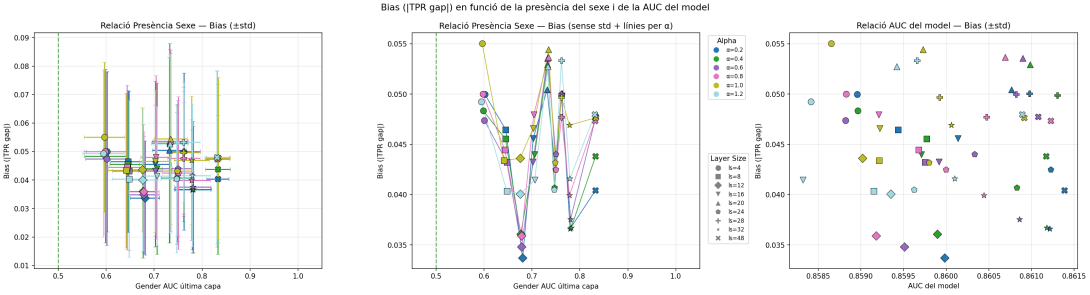
La magnitud de $\mathcal{L}_{\text{fair}}$ és massa petita per competir amb $\mathcal{L}_{\text{CE}}$ quan $\alpha$ és baix.

Cal un valor d'$\alpha$ molt superior perquè la penalització tingui efecte real.

## Conclusió parcial

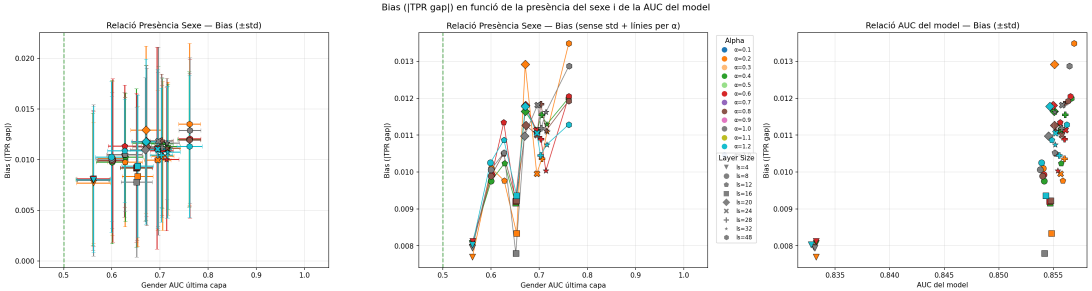
Penalitzacions febles ($\alpha < 1.2$) no produeixen cap efecte mesurable sobre el biaix ni sobre la codificació de gènere.

# E1 — NIH ChestX-ray, $\alpha \in [0.2, 1.2]$: penalització inerta




Les 6 condicions d'$\alpha$ se superposen en tots els panells: la variabilitat la determina *ls*.

# E2 — CheXpert, $\alpha \in [0.2, 1.2]$: penalització inerta




Idèntic patró al NIH. Biaix de partida 4 vegades menor ($\mathrm{GapTPR} \approx 0.010$ vs. 0.050).

# Resultat 2: Trade-off Equitat–Precisió a $\alpha$ Alt

**En experiments E3 i E4 ($\alpha \in [1, 1000]$):**

Es detecta un **llindar crític**:

- NIH: $\alpha^* \approx 25$–$50$
- CheXpert: $\alpha^* \approx 10$–$25$

| | AUC diag. | GapTPR |
|---|---|---|
| $\alpha = 0$ | 0.857 | 0.050 |
| $\alpha = 50$ | 0.682 | 0.010 |
| $\alpha = 1000$ | 0.525 | $\approx 0$ |

(NIH ChestX-ray)

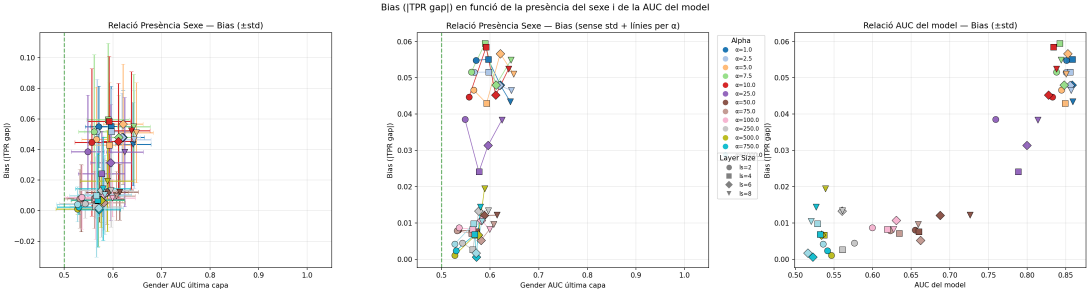
## Transició abrupta

Per sobre del llindar, el model abandona la tasca de diagnòstic per prioritzar l'equitat.

## Implicació

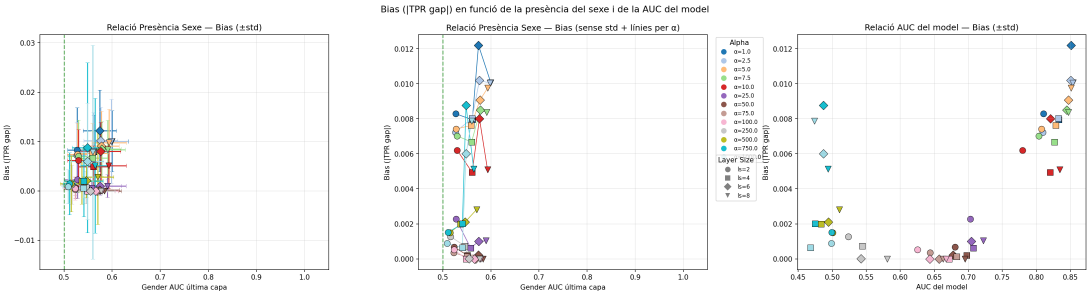
No hi ha *gratuïtat*: aconseguir equitat real requereix sacrificar precisió diagnòstica de forma significativa.

# E3 — NIH ChestX-ray, $\alpha \in [1, 1000]$: llindar crític visible




Panel dret: $\alpha$ creixent desplaça de dalt-dreta (alta AUC, alt biaix) cap a baix-esquerra. El llindar és visible.

# E4 — CheXpert, $\alpha \in [1, 1000]$: llindar crític anterior




El llindar arriba abans al CheXpert ($\alpha^* \approx 10$–$25$ vs. $\approx 100$ al NIH).

# Resum de Resultats

| | Troballa |
|---|---|
| **R1** | Penalitzacions febles ($\alpha < 1.2$) no redueixen el biaix ni la codificació de gènere |
| **R2** | Existeix un llindar crític $\alpha^*$ on l'equitat es compra a costa de la precisió diagnòstica |
| **R3** | *Is* és el principal determinant de la codificació; el backbone presenta $\mathrm{AUC} \approx 1.0$ sempre |
| **R4** | Els patrons qualitatius es repliquen entre NIH i CheXpert; les pràctiques del dataset impacten l'equitat tant com l'algorisme |

# Respostes a les Preguntes de Recerca

**RQ1** **Sí.** El gènere es codifica internament en totes les capes analitzades, inclosa la capa densa.

**RQ2** **Sí.** Una capa densa (*ls*) més gran permet recombinar la informació del backbone i augmenta la decodificabilitat lineal del gènere de forma monòtona.

**RQ3** **No de forma consistent.** La penalització d'equitat no incrementa la codificació de gènere — és la capacitat *ls* qui la determina. La hipòtesi paradoxal no es confirma.

# Contribucions i Implicacions Pràctiques

**Contribucions principals:**

- Anàlisi sistemàtica capa a capa de la codificació de gènere sota restriccions d'equitat
- Identificació del llindar crític on la penalització passa d'inerta a destructiva
- Evidència que la capacitat del model (*ls*), no la penalització, domina la codificació

**Implicacions per a la pràctica:**

- Penalitzacions febles no serveixen: cal $\alpha$ gran
- Penalitzacions fortes requereixen sacrificar precisió diagnòstica
- La codificació de gènere persisteix fins i tot amb $\alpha$ molt alt
- La qualitat i diversitat del **dataset és decisiva**

**Paradoxa de privacitat**

Models dissenyats per ser equitatius codifiquen activament el gènere

# Limitacions i Treball Futur

**Limitacions:**

- Biaixos intrínsecs baixos en ambdós datasets; cal validar en contexts amb major disparitat
- El linear probing detecta únicament codificació *lineal*; encodings no lineals podrien escapar-hi
- La mètrica Gap TPR no és l'única mesura d'equitat rellevant

**Treball futur:**

- Altres atributs protegits: ètnia, edat, tipus d'escàner
- Mètodes d'anàlisi no lineals: MMD, HSIC
- Validació clínica amb radiòlegs
- Datasets amb major disparitat (MIMIC-CXR)

# Gràcies per la vostra atenció

Joan Massallé Richart

Màster en Ciència de Dades — EPS, Universitat de Girona

Juny 2026

---

*Tutor: Jerónimo Hernández González*