Anàlisi de la codificació del gènere en representacions intermèdies d'una CNN per estudi d'equitat en predicció de Pneumònia

Joan Massallé Richart

Màster en Ciència de Dades
Escola Politècnica Superior, Universitat de Girona
Tutor: Jerónimo Hernández González

Juny 2026

Índex

1. Introducció
2. Metodologia i Objectius
3. Disseny Experimental
4. Resultats
5. Conclusions

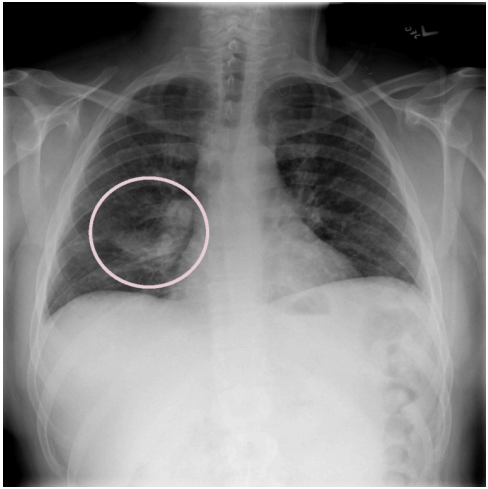
Motivació

Deep learning en diagnosi mèdica

- Rendiment comparable al d'un radiòleg expert en detecció de pneumònia
- Models entrenats sobre grans conjunts de radiografies de tòrax

Però...

- Els models aprenen i amplifiquen biaixos presents a les dades
- En context clínic: diagnòstic diferent per gènere, ètnia o edat



Rajpurkar et al., *PLOS Medicine* (2018)

Larrazabal et al., *PNAS* (2020)

Fairness en Diagnosi Mèdica

Garantir que els models **no discriminin** individus o grups en funció d'atributs sensibles: gènere, ètnia, edat...

Model globalment precís ⟶ **injust entre grups** ⟶ **conseqüències clíniques**

Com es mesura?

Paritat demogràfica
igual taxa de positius entre grups

Equal opportunity
igual sensibilitat (TPR) entre grups

Equalized odds
igual TPR *i* FPR entre grups

...

Seyyed-Kalantari et al., *CheXclusion*, PLOS Medicine (2021)

Mètodes per Aconseguir Equitat

Tres categories de mètodes:

Pre-processing Modificar o re-balancejar les dades *abans* d'entrenar

In-processing **Incorporar restriccions d'equitat durant l'entrenament**

Post-processing Ajustar les prediccions *després* d'entrenar

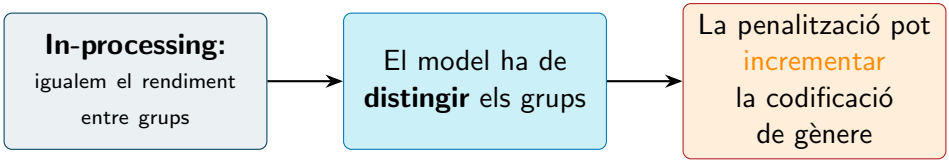
Estratègia d'aquest treball

Afegir una **penalització d'equitat** a la funció de pèrdua per igualar el rendiment entre homes i dones.

$\Rightarrow$ La literatura mostra que aquesta penalització acostuma a reduir el rendiment global: existeix un trade-off equitat–precisió.

Problema i Hipòtesi Central

Hipòtesi paradoxal:



Paradoxa de privacitat

Models dissenyats per ser equitatius poden codificar el gènere en les representacions latents.

Funció de Pèrdua amb Equitat

Pèrdua total

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{CE}} + \alpha \cdot \mathcal{L}_{\text{fair}}$$

Equal opportunity → Gap TPR:

$$\text{GapTPR} = |\text{TPR}_{\text{homes}} - \text{TPR}_{\text{dones}}|$$

El GapTPR no és derivable ⇒ s'aproxima amb les probabilitats del batch:

$$\mathcal{L}_{\text{fair}} = \left(\bar{p}_{\text{homes}} - \bar{p}_{\text{dones}}\right)^2$$

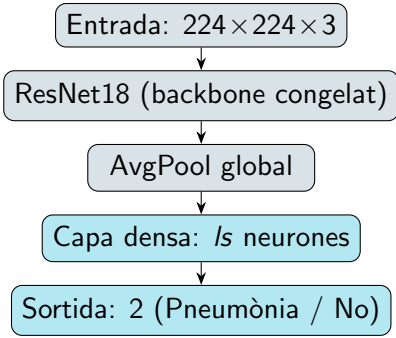
Motiu: derivada suau i aprenentatge més eficient

Hardt et al., *NeurIPS* (2016)

Règims de α:

- $\alpha = 0$: cap restricció d'equitat
- α baix $[0.2, 1.2]$: penalització suau
- α alt $[1, 1000]$: penalització forta

Arquitectura del Model



Dos paràmetres experimentals:

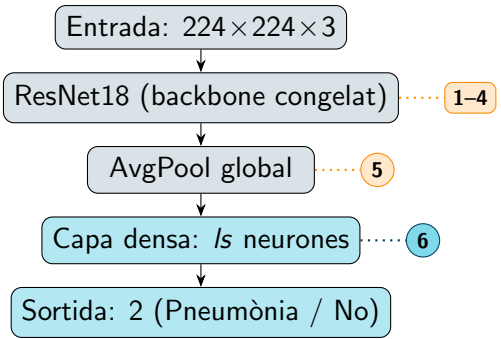
- α: força de la penalització d'equitat
- *ls*: capacitat de la capa densa intermèdia

Per què congelar el backbone?

Permet aïllar l'efecte de la penalització i del paràmetre *ls* sobre la codificació de gènere.

Mètode d'Anàlisi: Linear Probing

Idea: si el model "sap" el gènere, un classificador lineal sobre les activacions ho detectarà.



Mètrica: AUC ROC (gènere)

- $\mathrm{AUC} = 0.5 \Rightarrow$ cap codificació
- $\mathrm{AUC} = 1.0 \Rightarrow$ codificació perfecta

Per cada punt: regressió logística per predir el gènere.

Focus principal: punt **6** (capa dense *ls*) — l'únic que varia entre experiments.

Preguntes de Recerca

RQ1 Es codifica informació de gènere en les representacions intermèdies de la CNN, malgrat que no sigui una entrada explícita?

RQ2 Influeix la mida de la capa densa (*ls*) en la codificació de gènere?

RQ3 La penalització d'equitat (α) incrementa la codificació de gènere?

Conjunts de Dades

NIH ChestX-ray

- >100.000 radiografies de tòrax
- Biaix de gènere documentat a la literatura
- Permet estudiar l'efecte dels mètodes sobre un biaix real i conegut

Wang et al., *CVPR* (2017)

CheXpert (Stanford)

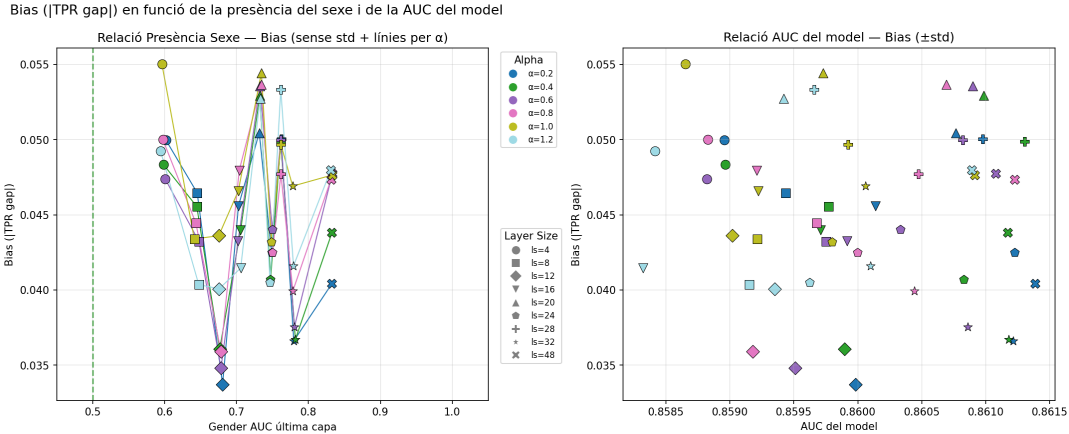
- >200.000 radiografies de tòrax
- Biaix de gènere documentat, de menor intensitat que el NIH
- Permet contrastar la robustesa dels resultats

Irvin et al., *AAAI* (2019)

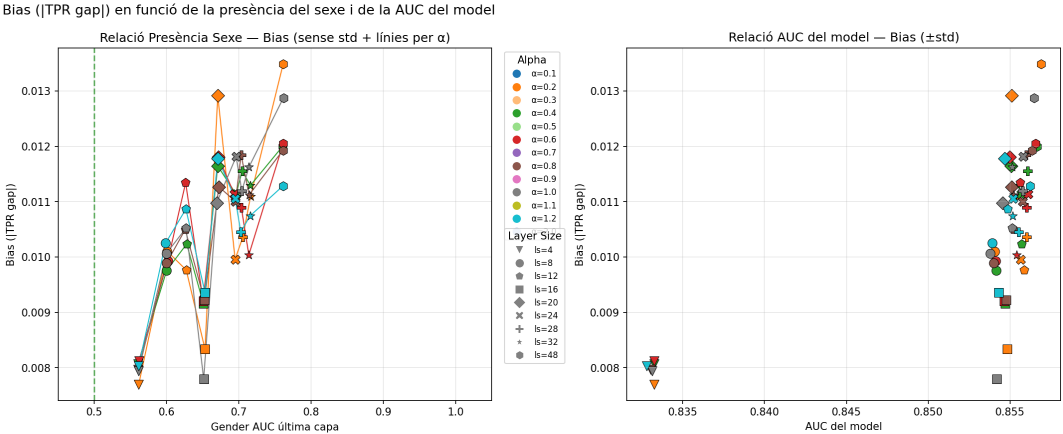
Disseny Experimental

Exp.	Dataset	Règim α	Valors *ls*	Models
E1	NIH ChestX-ray	[0.2, 1.2] (baix)	$\{4, 8, \ldots, 48\}$	1.080
E2	CheXpert	[0.2, 1.2] (baix)	$\{4, 8, \ldots, 48\}$	1.080
E3	NIH ChestX-ray	[1, 1000] (alt)	$\{2, 4, 8\}$	1.040
E4	CheXpert	[1, 1000] (alt)	$\{2, 4, 8\}$	1.040
			Total:	**4.240**

E1 — NIH ChestX-ray, $\alpha \in [0.2, 1.2]$: penalització inerta



E2 — CheXpert, $\alpha \in [0.2, 1.2]$: penalització inerta



Resultat 1: Penalització Inerta a α Baix

En experiments E1 i E2 ($\alpha \in [0.2, 1.2]$):

- El Gap TPR **no varia** significativament amb α
- L'AUC de gènere a la capa densa **no canvia** amb α
- Tota la variabilitat observada s'explica per *ls*, no per α

Interpretació

La magnitud de $\mathcal{L}_{\text{fair}}$ és massa petita per competir amb $\mathcal{L}_{\text{CE}}$ quan α és baix.

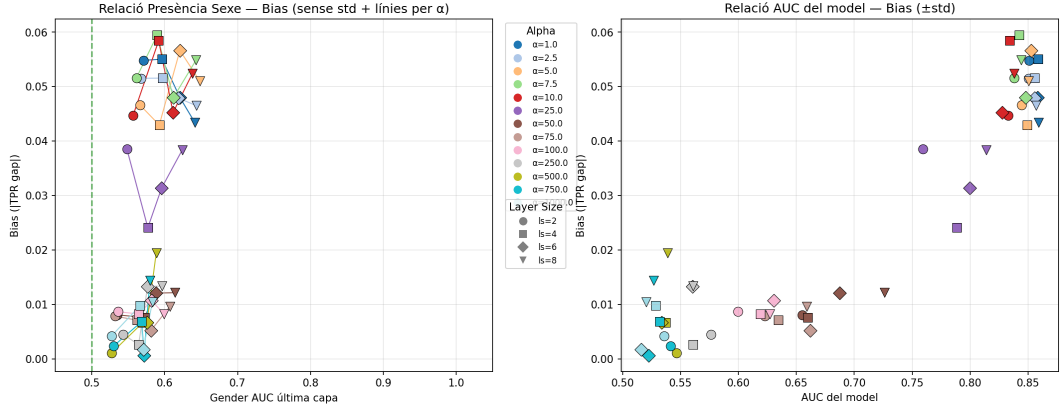
Cal un valor d'α molt superior perquè la penalització tingui efecte real.

Conclusió parcial

Penalitzacions febles ($\alpha < 1.2$) no produeixen cap efecte mesurable sobre el biaix ni sobre la codificació de gènere.

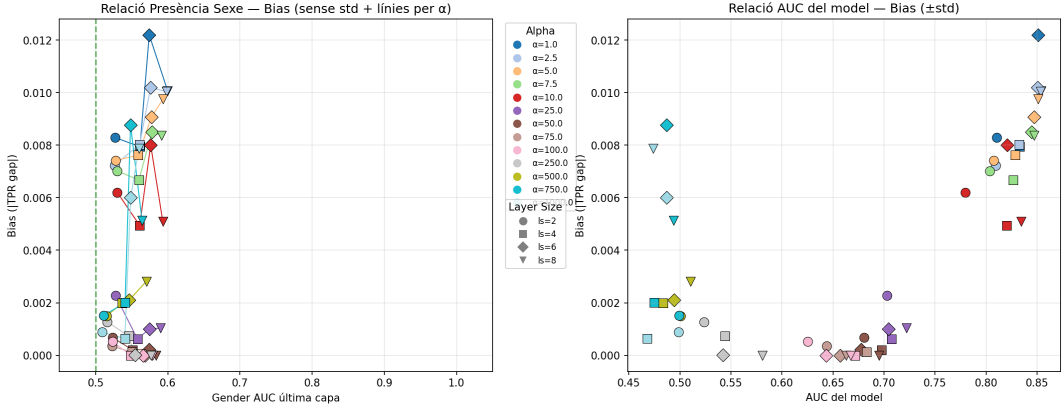
E3 — NIH ChestX-ray, $\alpha \in [1, 1000]$: llindar crític visible

Bias (|TPR gap|) en funció de la presència del sexe i de la AUC del model



E4 — CheXpert, $\alpha \in [1, 1000]$: llindar crític anterior

Bias (|TPR gap|) en funció de la presència del sexe i de la AUC del model



Resultat 2: Trade-off Equitat–Precisió a α Alt

En experiments E3 i E4 ($\alpha \in [1, 1000]$):

Es detecta un **llindar crític**:

- NIH: $\alpha^* \approx 25$–50
- CheXpert: $\alpha^* \approx 10$–25

	AUC diag.	GapTPR
$\alpha = 1$	0.839	0.051
$\alpha = 25$	0.767	0.025
$\alpha = 50$	0.580	0.000

(NIH ChestX-ray, $ls = 2$)

Transició abrupta

Per sobre del llindar, el model abandona la tasca de diagnòstic per prioritzar l'equitat.

Implicació

No hi ha *gratuïtat*: aconseguir equitat real requereix sacrificar precisió diagnòstica de forma significativa.

Resum de Resultats

- **Penalitzacions febles inefectives:** $\alpha \lesssim 10$ no mou ni el biaix ni la codificació de gènere
- **Llindar crític α^*:** per sobre, l'equitat s'aconsegueix però col·lapsant la precisió diagnòstica
- ***ls* domina la codificació:** capa densa més gran reté més gènere; α no és el factor determinant
- **Patrons replicats:** NIH i CheXpert mostren el mateix comportament qualitatiu

Respostes a les Preguntes de Recerca

RQ1 **Sí.** El gènere es codifica internament en totes les capes analitzades, inclosa la capa densa.

RQ2 **Sí.** Una capa densa (*ls*) més gran permet recombinar la informació del backbone i augmenta la decodificabilitat lineal del gènere de forma monòtona.

RQ3 **No de forma consistent.** La penalització d'equitat no incrementa la codificació de gènere — és la capacitat *ls* qui la determina. La hipòtesi paradoxal no es confirma.

Contribucions i Implicacions Pràctiques

Contribucions principals:

- Anàlisi sistemàtica capa a capa de la codificació de gènere sota restriccions d'equitat
- Identificació del llindar crític on la penalització passa d'inerta a destructiva
- Evidència que la capacitat del model (*ls*), no la penalització, domina la codificació

Implicacions per a la pràctica:

- Penalitzacions febles no serveixen: cal α gran
- Penalitzacions fortes requereixen sacrificar precisió diagnòstica
- La codificació de gènere és constant independentment de α
- La qualitat i diversitat del **dataset és decisiva**

Paradoxa de privacitat

Models dissenyats per ser equitatius codifiquen activament el gènere

Limitacions i Treball Futur

Limitacions:

- Biaixos intrínsecs baixos en ambdós datasets; cal validar en contexts amb major disparitat
- El linear probing detecta únicament codificació *lineal*; encodings no lineals podrien escapar-hi
- La mètrica Gap TPR no és l'única mesura d'equitat rellevant

Treball futur:

- Altres atributs protegits: ètnia, edat, tipus d'escàner
- Mètodes d'anàlisi no lineals: MMD, HSIC
- Validació clínica amb radiòlegs
- Datasets amb major disparitat (MIMIC-CXR)

Gràcies per la vostra atenció

Joan Massallé Richart

Màster en Ciència de Dades — EPS, Universitat de Girona

Juny 2026

Tutor: Jerónimo Hernández González